

重庆大学

硕士学位论文

基于人工神经网络与PID的复合控制研究

姓名：时文飞

申请学位级别：硕士

专业：电气工程

指导教师：侯世英

20070517

摘 要

传统的PID控制器由于结构简单、易于调整等优点,至今仍广泛应用于控制领域。但在实际的应用中,许多被控过程机理复杂,具有高度非线性、时变不确定性和纯滞后等特点。在噪声、负载扰动等因素的影响下,过程参数甚至模型结构均会随时间和工作环境的变化而变化,这时采用传统的PID控制就不能取得令人满意的控制效果。

人工神经网络 ANN (Artificial Neural Network) 具有自学习、自适应和自组织的能力,将 ANN 与传统的 PID 控制结合,构成智能型的神经网络 PID 控制器,能够自动辨识被控过程参数、自动整定控制参数、适应被控过程参数的变化,是解决传统 PID 控制器参数整定难、不能实时调整参数和鲁棒性不强的有效措施。

本文在分析研究了国内外神经网络 PID 复合控制结构方案的基础上,针对神经网络在线调整 PID 参数以及 CMAC (Cerebellar Model Articulation Controller) 与 PID 的复合控制这两种控制方案,采用理论加仿真的方法进行研究。主要的工作和结论如下:

(1) 指出基于神经网络在线调整 PID 参数的控制方案中一般采用全局学习神经网络(如 BP 网络),存在学习速度慢,并且容易陷入局部极小的缺点。通过一个具体实例的仿真结果,在跟踪方波信号时,反应比较“迟钝”,跟踪误差大,不能满足实时控制的要求。

(2) 提出一种 CMAC 概念映射算法,给出了算法公式。

(3) 提出了改进型 CMAC-PID 控制方案。改进型 CMAC-PID 控制器中,通过系统误差调整联想存储空间中的权值,并采用变学习速率的结构,使得 CMAC 的学习为包含了 PID 控制器在内的整个系统的逆动态模型,有效克服原有控制结构,在跟踪连续变化信号时,由于 CMAC 和 PID 相互作用,产生过学习导致系统不稳定的现象。另外,把状态相量引入 CMAC 网络的输入空间,充分利用了 CMAC 中已存储的信息,提高了抗干扰能力,在跟踪方波信号时,学习速度快,输出误差小,体现了良好的控制性能。

(4) 将改进型 CMAC-PID 控制器用于非线性及时变性非常突出的柴油发电机组调速系统,建立了火电厂应急柴油发电机组的仿真模型,仿真结果表明在顺序投入负载时,应急柴油发电机组在改进型 CMAC-PID 控制下比常规 PID 控制下有更好的动态性能——转速(频率)瞬态调整率小和稳定时间(调节时间)短,克服了常规控制器不能避免的一些弊端,提高了控制效果。

关键词：人工神经网络，PID，非线性，复合控制，柴油发电机组

Abstract

With simple structure and easy debugging, conventional PID controller is still widely used on the industrial area today, especially suit for the deterministic system with precise mathematical model. In the actual application, many controlled process are high nonlinear, time-variation, probabilistic and lag, the procedure parameters even the model structure vary along with the time and work environment, under the influence of noise and load disturbance. In this case, it can not obtain satisfied control effect using conventional PID controller.

Artificial neural network is an important branch of intelligent control, it has the ability of self study, self adapting and self-organizing. So combining the ANN and the PID, make the compound ANN-PID controller identify and set the controlled process parameter automatic, can solve the problem of conventional PID controller with difficult parameter setting, unforcement robustness and can not tune the parameter real-time.

On the basis of investigation on the ANN-PID compound control scheme at home and abroad, this paper puts emphasis on studying two compound control schemes with the method of theory and simulation. One is tuning the PID parameter online using ANN and the other is the compound control based on CMAC and PID.

The main works and conclusions in this paper are as follows:

(1) The control scheme of tuning the PID parameter online using ANN, the ANN in this scheme is used global ANN (e.g. BP), the drawbacks of the global ANN determines the drawbacks of the ANN-PID compound control scheme, the study speed is low and easy trapped in local minimum. Under the simulation on a specific example, the simulation result indicates that when this compound control scheme tracing the square wave signal, its response is obtuse and can not use for real-time control.

(2) A new conceptual mapping algorithm of CMAC is proposed.

(3) Modified CMAC-PID controller is proposed. In the conventional CMAC-PID controller, for the conflict between CMAC and PID, the system may become unstable a long time later. In the modified CMAC-PID controller, lead the system error to the study algorithm of CMAC to tune the weights of the association units. In the new scheme, the study of CMAC implements the inverse dynamic model of the whole system including the PID controller. The simulation results indicate that the modified

CMAC-PID controller avoids the unstable phenomenon , when tracing the square wave signal the error is smaller than under control of conventional CMAC-PID controller and general PID controller. The modification is effective.

(4) The diesel generator set is controlled using modified CMAC-PID controller which is high nonlinear and time-variation. The diesel generator set model in the heat-engine plant is developed under the environment of MATLAB SIMULINK. The simulation results indicate that the dynamic performance of emergency diesel generator set under the control of modified CMAC-PID controller is better than under the control of conventional CMAC-PID controller and general PID controller, with smaller transient adjustment rate and stabilization time. The modified compound scheme avoids the drawbacks of the general PID controller and increases the control effect.

Keywords: ANN, PID, compound control, nonlinear, diesel generator set

独 创 性 声 明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得重庆大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：时文

签字日期：2007 年 5 月 25 日

学位论文授权使用授权书

本学位论文作者完全了解重庆大学有关保留、使用学位论文的规定，有权保留并向国家有关部门或机构送交论文的复印件和磁盘，允许论文被查阅和借阅。本人授权重庆大学可以将学位论文的全部或部分内 容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

保密（ ），在____年解密后适用本授权书。

本学位论文属于

不保密（☒）。

（请只在上述一个括号内打“√”）

学位论文作者签名：时文

导师签名：侯世英

签字日期：2007 年 5 月 25 日

签字日期：2007 年 5 月 25 日

1 绪论

1.1 研究背景与动机

传统的PID控制器由于结构简单、易于调整,以及特别适用于可建立精确数学模型的确定性控制系统等优点,至今工业过程控制80%回路还都采用的是PID控制策略。在PID控制中一个至关重要的问题是参数(比例、积分、微分)的整定,典型的PID参数整定方法是在获取对象数学模型的基础上,根据一定整定原则来确定PID参数^[1]。

另一方面,在实际的应用中,许多被控过程机理复杂,具有高度非线性、时变不确定性和纯滞后等特点。在噪声、负载扰动等因素的影响下,过程参数甚至模型结构均会随时间和工作环境的变化而变化。这时采用传统的PID控制就不能取得令人满意的控制效果。

建立被控对象的数学模型是十分复杂的事情,在建立过程中常常需要将系统降阶或将系统以线性化近似,或忽略系统中某些认为不重要的参数,以简化分析难度。因此,到最后所得到的数学模型,即使可快速且精确地算出控制量,但与实际的物理系统可能出现相当大的差距,容易与实际脱节,导致产生性能不佳的控制。

PID参数整定的优劣不但会影响到控制质量,而且还会影响到控制系统的稳定性和鲁棒性。在一篇关于加拿大造纸厂的统计报告中表明,一座典型的造纸厂一般有2000多个控制回路,其中97%以上的回路采用PID控制,但仅有20%的控制回路工作比较满意,控制回路性能普遍偏差的原因中,参数整定不合适占30%,阀门问题占30%,传感器问题、采样频率选取问题、滤波问题等占20%^[2]。可见PID的参数整定是非常重要的。

人工神经网络(ANN)作为智能控制的一个重要分支领域,具有自学习、自适应、组织的能力,因此将ANN与传统的PID控制结合,构成智能型的神经网络PID控制器,能够自动辨识被控过程参数、自动整定控制参数、能够适应被控过程参数的变化,是解决传统PID控制器参数整定难、不能实时调整参数和鲁棒性不强的有效措施,使PID控制器具有经久不衰的生命力^[3],是智能控制器的一个有潜力的发展方向。

当前神经网络与PID控制相结合的方案有多种,但应用于实际的还相对较少,除去人工神经网络在设计和制造问题上存在的困难以外,控制结构和控制算法的成熟和可靠性也是一个重要的因素,这也就是本论文的研究动机。

1.2 智能控制的发展概况

智能控制是一门新兴学科,其技术随着数字计算机、人工智能等技术的发展而发展起来的。所谓智能控制,即设计的控制器(或系统),具有学习、抽象、推理、决策等功能,并能根据环境(包括被控对象或被控过程)信息的变化做出适应性反应,从而实现由人来完成的任务。

1.2.1 传统控制理论遇到的困难^{[4][5][6]}

自从美国数学家维纳在四十年代提出控制论以来,作为工程控制论核心的自动控制理论一般可分为2个阶段:

① 经典控制理论时期。时间是20世纪40—60年代。经典控制理论主要解决单输入单输出的问题,主要采用传递函数模型、频域分析与综合方法,所研究的系统多是线性定常系统。

② 现代控制理论时期。时间为20世纪60—70年代。主要采用状态方程、时域分析与综合方法,研究多变量控制系统设计。现代控制理论可以解决多输入多输出的问题,系统即可以是线性的、定常的,也可以是非线性的、时变的。

尽管传统控制理论已经形成了完整的理论体系,控制系统在大规模产业化方面也取得了可喜的成果。但是,它对精确数学模型的依赖性,使其应用受到很大的限制。因为其分析、综合和设计都是建立在严格和精确的数学模型基础之上,同时随着科学技术和生产力水平高速发展,被控对象结构的日益复杂,以及人们对大规模、复杂和不确定性系统实行自动控制的要求不断提高,传统的基于精确数学模型的控制理论的局限性日益明显。

传统控制系统的设计与分析是建立在精确的系统数学模型基础上,而实际系统由于存在复杂性、非线性、时变性、不确定性和不完全性等,一般无法获得精确的数学模型。

传统控制理论在应用中面临的难题包括:

① 不适应非线性系统的控制。一般控制系统都具有非线性特性,当非线性特性的影响较小时,传统控制理论通常将其近似线性化后设计控制器。当被控制系统具有高度非线性特性时,在传统控制理论中虽然也有一些方法可用,但是只针对一些具体问题,有较多的附加条件,大多数过于复杂而难以实际运用。

② 不适应时变系统的控制。实际被控系统的结构和参数随时间而发生变化,绝对不变的系统是不存在的。当这种变化较小时,经过一系列的近似后,才能利用传统控制理论进行系统综合。如果时变因素较大,传统控制理论则无法应用。

③ 不适应多变量系统的控制。多变量系统的控制问题一直是控制理论界和控制工程界研究的重点和难点问题,多变量系统除了与单变量系统一样存在着不确定性,非线性和时变问题以外,还存在着各要素间相互耦合、互相制约等特殊问

题。如果多变量系统为线性时不变而且结构和参数已知，还可以应用传统控制理论设计解耦器和控制器，对多变量系统进行控制。如果以上条件不成立，传统控制理论则无法应用，而在实际中这些条件一般很难满足。

传统控制理论虽然也有办法，对付控制对象的不确定性和复杂性，如自适应控制和鲁棒（Robust）控制也可以克服系统中包含的不确定性，达到优化控制的目的。从本质上说，自适应和自校正控制都是通过对系统某些重要参数的估计，以补偿的方式来克服干扰和不确定性。它比较适合系统参数在一定范围内的慢变化情况。鲁棒控制则是在一定的外部干扰和内部参数变化作用下，以提高系统的不灵敏度为宗旨来抵御不确定性。根据这一思想和原理所导出的算法，其鲁棒的区域是有限的。

因此在实际应用中，尤其在工业过程控制中，由于被控对象的严重非线性，数学模型的不确定性，系统工作点变化剧烈等因素，自适应和鲁棒控制存在着难以弥补的严重缺陷，其应用的有效性受到很大的限制，这就促使人们提出新的控制技术和方法。

1.2.2 智能控制的产生和发展^{[7][8]}

智能控制是自动控制发展的最新阶段，主要用于解决传统控制难以解决的复杂的控制问题。控制科学的发展过程如图 1.1 所示。




图 1.1 控制科学的发展过程

Fig 1.1 The development of cybernetics

人工智能的发展促进了传统控制向智能控制的发展。遗憾的是在相当长时间内，很少人提到控制理论与人工智能的联系。1965 年，著名的美籍华裔科学家傅

京逊教授首先把人工智能的启发式推理规则用于学习控制系统,然后,他又于 1971 年论述了人工智能与控制理论的交接关系。由于傅京逊教授的重要贡献,他已成为国际公认的智能控制的先行者和奠基人。

1965 年,扎德(Zadeh)发表了他的著名论文“模糊集合”(fuzzy sets),开辟了模糊控制的新领域。此后模糊控制的理论探索 and 实际应用两个方面都进行了大量的研究,并取得了一批成果。

美国学者 G.N.Saridis 在 1977 年在傅京逊把智能控制为人工智能与自动控制的交叉(二元论)的基础上,引入运筹学,提出了三元论的智能控制概念,即

$$IC = AC \cap AI \cap OR \quad (1.1)$$

式中各子集的含义: IC 为智能控制(Intelligent Control); AI 为人工智能(Artificial Intelligence); AC 为自动控制(Automatic Control); OR 为运筹学(Operational Research)。基于三元论的智能控制如图 1.2 所示。




图 1.2 智能控制的三元结构

Fig 1.2 Ternary configuration of intelligent control

进入 20 世纪 80 年代以来,奥斯特罗姆(Astrom)、迪席尔瓦(de Silva)、周其鉴、蔡自兴、霍门迪梅洛(Homen de Mello)和桑德森(Sanderson)等人分别提出和发展了专家控制、基于知识的控制、仿人控制、专家规划和分级规划等理论。特别是 80 年代中后期,由于神经网络的研究获得了重要进展,于是在这一领域吸引了众多学科的科学、学者。如今在控制、计算机、神经生理学等学科的密切配合下,在“智能控制理论”的旗帜下,又在寻求新的合作,神经网络理论和应用研究为智能控制研究起到了重要的促进作用。20 世纪 90 年代以来,智能控制的研究势头异常迅猛,1992 年 4 月,美国国家自然科学基金和美国电力研究院发出《智能控制》研究项目倡议书。

近年来,神经网络、模糊数学、专家系统、进化论等各门学科的发展给智能

控制注入了巨大的活力，由此产生了各种智能算法。

1.2.3 智能控制的研究对象和功能

智能控制的研究对象应具有以下特点：

① 模型的不确定性

传统的控制是基于模型的控制，其模型通常认为已知或者经过辨识可以得到，而智能控制的对象通常存在严重的不确定性。这里所说的模型不确定性包含两层意思：一是模型未知或知之甚少；二是模型的结构和参数可能在很大范围内变化。无论哪种情况传统的方法都难以对他们进行控制，而这正是智能控制所要研究解决的问题。

② 高度的非线性

在传统的控制理论中，线性系统比较成熟，对于具有高度非线性的控制对象，虽然也有一些非线性控制方法，但总的来说，非线性控制理论都很不成熟，而且方法比较复杂。采用智能控制的方法往往可以比较好的解决非线性控制问题。

③ 复杂的任务要求

在传统的控制系统中，控制的任务是要求输出量为定值（调节系统），或者要求输出量跟随期望的运动轨迹，因此控制任务的要求比较单一。对于智能控制系统，任务的要求往往比较复杂。如在智能机器人系统中，要求系统对复杂的任务有自行规划和决策的能力，有自动躲避障碍运动得到期望目标位置的能力。

面对现代化工业的特点和要求，一个理想的智能控制系统应具备以下一些功能特点：

① 学习功能

系统具有自行改善自身性能的能力，即在经历某种变化后，系统性能优于变化前的系统性能。

② 自适应功能

系统应具有适应受控对象动力学特性变化、环境变化和运行条件变化的能力。

③ 自组织功能

指的是对于复杂任务和分散的传感信息具有自行组织和协调能力，该组织功能也表现为系统具有相应的主动性和灵活性，即智能控制器可以在任务要求的范围内自行决策、主动地采取行动，而当出现多目标冲突时，在一定的限制下，控制器可有权自行裁决。

④ 鲁棒性

系统应对环境干扰和不确性等因素不敏感。

⑤ 容错性

系统应对各种故障具有自修复的功能。

⑥ 实时性

实时性是智能控制所必备的性能，系统应具有相当的在线实时响应能力。

1.2.4 智能控制的几个重要分支^[9]

智能控制的几个重要分支为专家控制、模糊控制、神经网络控制和遗传算法等。

① 专家控制

专家控制系统是把专家系统技术应用于控制过程的系统。专家系统模拟人工控制防范和操作员的经验知识，结合控制算法，实现对过程或事件的控制。在直接专家控制系统中，专家系统直接给出控制信号，影响控制过程，而在间接专家控制系统中，专家系统位于外环或监控级中，专家系统通过层间界面指导内环或执行级的工作，专家系统只是通过对控制其的结构或参数进行调整，间接地影响控制过程。由于专家控制系统不需要被控制对象的数学模型，因此它是目前解决不确定性系统的一种有效方法，应用较为广泛。

② 模糊控制

模糊控制是智能控制较早的形式，它吸取了人的思维具有模糊性的特点，从广义上讲，模糊控制指的是应用模糊集合理论，统筹考虑系统的一种控制方式，模糊控制不需要精确的数学模型，是解决不确定性系统控制的一种有效途径。

③ 神经网络控制

将神经网络引入控制领域就形成了神经网络控制。神经网络控制是从机理上对人脑生理系统进行简单结构模拟的一种新兴智能控制方法。神经网络具有并行机制、模式识别、记忆和自学习能力的特点，它能充分逼近任意复杂的非线性系统，能够学习和适应不确定系统的动态特性，有很强的鲁棒性和容错性。神经网络控制在控制领域有着广泛的应用。

④ 遗传算法

遗传算法（Genetic Algorithm, GA）是人工智能的一个重要分支，是基于自然选择和基因遗传学原理的搜索算法，是基于达尔文进化论，在计算机上模拟生命进化论机制而发展起来的一门学科。目前遗传算法已经被广泛应用于许多实际问题，成为用来解决高难度复杂问题的新思路和方法。

⑤ 仿人控制系统

仿人控制（Human-Simulated Control）的思想是重庆大学周其鉴于1983年正式提出的，现在已经形成了基本理论体系和比较系统的设计方法。其基本思想就是在模拟人的控制结构的基础上，进一步研究和模拟人的控制行为和功能，并把它用于控制系统，实现控制目标。

⑥ 免疫控制系统

自然免疫系统是个复杂的自适应系统，能够有效地运用各种免疫机制防御外部病原体的入侵。把免疫控制和计算方法用于控制系统，则可构成免疫控制系统。

1.3 神经网络简介^{[10][11]}

1.3.1 神经网络发展概述

1943 年心理学家 M.McCulloch 和数学家 W. Pitts 首先提出了一个简单的神经网络模型，其神经元的输入输出关系为：

$$y_i = \text{sgn}(\sum_j w_{ji} x_j - \theta_i) \quad (1.2)$$

其中输入、输出均为二值量， w_{ji} 为固定的权值。利用该简单网络可以实现一些逻辑关系。虽然该模型很简单，但它为进一步的研究打下基础。

1949 年 D.O.Hebb 首先提出了一种调整神经网络连接权的规则，通常称为 Hebb 学习规则。其基本思想是当两个神经元同时兴奋或同时抑制时，则它们的连接强度便增加。

$$w_{ji} = \begin{cases} \sum_{k=1}^n x_i^{(k)} x_j^{(k)} & i \neq j \\ 0 & i = j \end{cases} \quad (1.3)$$

该学习规则的意义，连接权的调整正比于两个神经元活动状态的乘积，连接权是对称的，神经元到自身的连接权为零。现在有不少的神经网络采用这样的学习规则。

1958 年 F.Rosenblatt 等人研究了一种特殊类型的神经网络，称为“感知机”（perceptron）。他们认为这是生物系统感知外界传感信息的简化模型。该模型主要用模式分类；并一度引起人们的广泛兴趣。

1969 年 M.Minsky 和 S.Papert 发表了名为“感知机”的专著。它们在这本专著中指出简单的线性感知机的功能是有限的，它无法解决线性不可分的两类样本的分类问题。典型的例子如“异或”计算，要解决这个问题，必须加入隐层结点。但是对于多层网络，如何找到有效的学习算法尚是难于解决的难题。因此它使得整个 70 年代神经网络的研究处于低潮。

美国物理学家 J.J.Hopfield 在 1982 和 1984 年发表了两篇神经网络的文章，引起了很大的反响。他提出了一种反馈互联网，定义了一个能量函数，它是神经元的状态和连接权的函数，利用该网络可以求解和优化计算的问题。该网络后来成为 Hopfield 网，最典型的例子是应用该网络成功的求解了旅行商最优路径的问题。

1986 年 D.E.Rumelhart 和 J.L.McClelland 等人提出了多层前馈网的反向传播算法（Back Propagation），以后简称 BP 网络或 BP 算法。该算法解决了感知机所不

能解决的问题。

Hopfield 网和反向传播算法的提出使人们看到了神经网络的前景和希望。1987 年在美国召开了第一届国际神经网络会议，它掀起了神经网络研究的热潮，许多研究人员都企图找到神经网络在各自领域的应用。

1.3.2 神经网络原理

人工神经网络是以数学手段模拟人脑神经网络的结构和特征的系统。它由大量的处理单元（神经元）广泛连接而成，是对人脑的抽象、简化和模拟，反映人脑的基本特性。

一般来说，作为神经元模型应具备以下三个要素：

- ① 具有一组突触或连接，常用 w_{ij} 表示神经元 i 和神经元 j 之间的连接强度，一般称之为权值。与人脑神经元不同，人工神经元权值的取值可在负值与正值之间。
- ② 具有反映生物神经元时空整合功能的输入信号累加器。
- ③ 具有一个激励函数用于限制神经元输出。激励函数将输出信号压缩（限制）在一个允许范围内，使其成为有限值，通常，神经元输出的扩展范围在 $[0, 1]$ 或 $[-1, 1]$ 闭区间。

我们用 MP 模型来说明人工神经网络的原理。MP 模型是由美国心理学家 McCulloch 和数学家 Pitts 于 1943 年共同提出的人工神经元模型，MP 模型下图 1.3 所示，它是一个多输入多输出的非线性信息系统处理单元。图中， y_j 表示神经元 j 的输出，它可以与其他多个神经元通过权连接； y_i 表示与神经元 j 连接的神经元 i 的输出，也是神经元 j 的输入； w_{ij} 为神经元 i 至 j 的连接权值； θ_j 为神经元 j 的阈值； $f(x_j)$ 为神经元 j 的激励函数。神经元 j 的输出 y_j 可以用下式描述：




图 1.3 人工神经元模型

Fig 1.3 The nerve unit model of ANN

$$\begin{cases} y_j = f(x_j) \\ x_j = \sum_{i=1}^n w_{ij} y_i - \theta_j \end{cases} \quad (1.4)$$

每一个神经元的输出为“0”或“1”，分别表示“抑制”或“兴奋”状态，则

$$f(x) = \begin{cases} 1, x \geq 0 \\ 0, x < 0 \end{cases} \quad (1.5)$$

$f(x)$ 是一个激励函数。式 (1.5) 所示的激励函数为阶跃函数，如图 1.4 所示，由公式 (1.4) 知，当神经元 j 的输入信号加权和超过阈值时，输出为“1”，即兴奋状态；反之，输出为“0”，是“抑制状态”。

若把阈值也看成一个权值，则 (1.4) 式可以写成

$$y_j = f\left(\sum_{i=0}^n w_{ji} y_i\right) \quad (1.6)$$

式中， $w_{0j} = -\theta_j$ ， $y_0 = 1$ 。




图 1.4 阶跃函数

Fig 1.4 Phase step fuction

以上就是 MP 模型，MP 神经元模型是人工神经元模型的基础，在神经元模型中，激励函数除了在 MP 模型中的阶跃函数外，还有以下几种形式：

① 符号函数

$$\text{sgn}(x) = \begin{cases} 1, x \geq 0 \\ -1, x < 0 \end{cases} \cdots \quad (1.7)$$

符号函数也常常作为神经元函数的激励，如图 1.5 所示。




图 1.5 符号函数

Fig 1.5 Symbolic function

② 分段性函数

该函数在 $[-1, 1]$ 线性区内的放大系数是一致的。图 1.6 所示。

$$f(x) = \begin{cases} 1, & x \geq 1 \\ x, & -1 < x < 1 \\ -1, & x \leq -1 \end{cases} \quad (1.8)$$




图 1.6 分段性函数

Fig 1.6 Segmentation function

③ 非对称型的 Sigmoid 函数

如图 1.7 所示，非对称型的 Sigmoid 函数是可微的，用下式表示

$$f(x) = \frac{1}{1 + e^{-x}} \quad (1.9)$$




图 1.7 非对称型 Sigmoid 函数

Fig 1.7 Unsymmetric form Sigmoid function

④ 对称型 Sigmoid 函数

如图 1.8 所示，对称型 Sigmoid 函数是可微的，用下式表示：

$$f(x) = \frac{1 - e^{-x}}{1 + e^{-x}} \quad (1.10)$$




图 1.8 对称型 Sigmoid 函数

Fig 1.8 Symmetric forme Sigmoid function

1.3.3 神经网络的分类

人工神经网络是以数学手段模拟人脑神经网络的结构和特征的系统。利用人工神经元可以构成各种不同拓扑结构的神经网络，从而实现对生物神经网络的模拟。目前神经网络模型的种类相当丰富，已有近 40 余种神经网络模型，其中典型的有多层前向传播（BP 网络）、Hopfield 网络、CMAC 小脑模型网络、ART 自适应共振理论、BAM 双向联想记忆、SOM 自组织网络、Blotzman 机网络和 Madaline 网络等。

根据神经网络的连接方式，神经网络可以分为 3 种形式。

① 前馈网络

网络分为若干层，各层依次排列，第 i 层神经元只接受 $i-1$ 层神经元的输出信号，各神经元之间没有反馈。如图 1.9 所示。前馈网络的例子有在多层感知器（MLP）、学习矢量化（LVQ）网络、小脑模型连接控制器（CMAC）和数据处理方法等（GMDH）网络等。




图 1.9 前馈型神经网络模型示意图

Fig 1.9 The map of feedforward ANN model

② 反馈（递归）网络

在反馈型神经网络中，每个节点都表示一个计算单元，同时接受外加输入和其他节点的反馈输入，甚至包括自环反馈每个节点也直接向外部输出。如图 1.10 所示。Hopfield 网络、Elman 网络和 Jordon 网络是反馈网络有代表性的例子。




图 1.10 反馈型神经网络模型示意图

Fig 1.10 The map of feedback ANN model

③ 自组织网络

网络结构如图 1.11 所示，Kohonen 网络是典型的自组织网络。Kohonen 认为当前神经网络在接受外界输入时，网络将会分成不同的区域，不同区域具有不同的相应特征，即不同的神经元以最佳方式响应不同性质的信号激励，从而形成一种拓扑意义上的特征图，该图实际上是以中非线性映射。这种映射是通过无监督的自适应过程完成的，所以也称为自组织特征图。Kohonen 网络通过无导师的学习方式进行权值的学习，稳定后的网络输出就对输入模式生成自然的特征映射，从而达到自动聚类的目的。




图 1.11 自组织神经网络

Fig 1.11 Self-organized ANN

1.3.4 神经网络的学习算法

神经网络学习算法是神经网络智能特性的重要标志，神经网络通过学习规则，实现了自适应、自组织和自学习的能力。

目前神经网络的学习算法有多种，按有无导师分类，可分为有导师学习（Supervised Learning）、无导师学习（Unsupervised Learning）和再励学习

(Reinforcement Learning) 等几类。在有导师的学习方式中, 网络的输出和期望的输出 (即导师信号) 进行比较, 然后根据两者之间的差异调整网络的权值, 最终使差异变小, 如图 1.12 所示。在无导师的学习方式中, 输入模式进入网络后, 网络按照一种预先设定的规则 (如竞争规则) 自动调整权值, 使网络最终具有模式分类功能, 如图 1.13 所示, 再励学习是介于上述两者之间的一种学习方式。




图 1.12 有导师的神经网络学习

Fig 1.12 Supervised learning of ANN




图 1.13 无导师的神经网络学习

Fig 1.13 Unsupervised learning of ANN

常用的三种主要规则是:

① 无监督 Hebb 学习规则

Hebb 学习是一种相关学习, 它的基本思想是: 如果有两个神经元同时兴奋, 则它们之间的连接强度的增强和它们的激励的乘积成正比。Hebb 学习规则用下式表示

$$\Delta w_{ij}(k) = \eta o_i(k) o_j(k) \quad (1.11)$$

式中 η ——学习速率, o_i 表示单元 i 的激活值, o_j 表示单元 j 的激活值 w_{ij} 表示单元 j 到单元 i 的连接加权系数。

② 有监督 δ 学习规则

在 Hebb 学习规则中引入教师信号 d_i , 有监督 δ 学习规则如下:

$$\Delta w_{ij}(k) = \eta [d_i(k) - o_i(k)] o_j(k) \quad (1.12)$$

③ 有监督 Hebb 学习规则

将无监督的 Hebb 学习规则和有监督 δ 学习规则两者结合起来, 组成有监督

Hebb 学习规则即:

$$\Delta w_{ij}(k) = \eta [d_i(k) - o_i(k)] o_j(k) \quad (1.13)$$

1.3.5 神经网络用于控制领域

神经网络智能处理能力及控制系统所面临的越来越严重的挑战是神经网络控制的发展动力。由于神经网络本身具备传统的控制手段无法实现的一些优点和特征,使得神经网络控制器的研究迅速发展。从控制角度看,神经网络用于控制的优越性主要表现在^[1]:

① 能够充分逼近任意复杂的非线性关系,从而形成非线性动力学系统,以表示某些被控对象的模型或控制器模型。

② 能够学习和适应不确定性系统的动态特性。

③ 所有定量或定性的信息都分布存储于网络内的各神经单元,从而具有很强的容错性和鲁棒性。

④ 采用信息的分布式并行处理,可以进行快速大量的运算。

⑤ 硬件实现。神经网络不仅能够通过软件而且可以借助硬件实现并行处理。近年来,一些超大规模集成电路实现硬件已经问世,而且可从市场上购买到。这使得神经网络具有快速和大规模处理能力得以实现。

随着人工神经网络研究的进展,神经网络越来越多的应用于控制领域的各个方面。从过程控制、机器人控制、生产制造、模式识别直到决策支持都有许多应用神经网络的例子。本文所研究的将神经网络与传统 PID 控制器结合起来,通过它们的有机结合来取长补短,构成新型控制器,也是在这个大环境下产生的。

1.4 本文研究目的和研究内容

1.4.1 本文的研究目的

① 广泛查阅神经网络与 PID 的文献资料,掌握神经网络及 PID 的结构及运行机理,对现有神经网络与 PID 复合控制的结构方案进行比较分析,找出其优缺点。

② 针对现有神经网络与 PID 复合控制结构中存在的问题,通过分析找出其出现问题的原因,并以此为基础,对现有控制结构进行改进,使其更能发挥神经网络和 PID 各自的优势,能够适用于有高度非线性、时变不确定性的系统,创造出更加优良的控制器。

③ 将改进后的神经网络与 PID 复合控制方案,用于非线性及时变性都非常突出的柴油发电机组调速系统,通过仿真与改进前及传统的控制方案比较,验证改进后的控制效果。

1.4.2 本文研究的主要内容

① 第一章,较系统地阐述了传统控制理论遇到的困难,并对智能控制、神经

网络的发展状况作了综述,在这个大背景下,说明了本论文的研究动机及研究目的。

② 第二章,讨论了神经网络在控制中的应用情况,包括控制结构、特点及其实现方法,指出当前一般的神经网络直接用于控制还存在缺陷,把神经网络与应用非常成熟的 PID 控制器“集成”,是能取长补短,提高控制性能的有效途径。论述了 PID 控制算法及其改进算法。

③ 第三章,研究了神经网络与 PID 复合控制的三种控制方案。基于单神经元的 PID 控制、神经网络在线调整 PID 控制参数的方案和 CMAC 与 PID 复合控制方案。重点研究了后两种方案,以 BP 神经网络 PID 控制为例,讨论了神经网络在线调整 PID 控制参数方案的控制结构、控制原理和控制算法,以一具体实例对其控制效果进行了仿真分析,并与传统的 PID 控制方案相比较,指出了其优缺点。

深入分析了小脑模型控制器(CMAC)的体系结构和运行机制,在此基础上,推导了一种易于软件实现的,适用于一维到多维输入的概念映射算法。传统的 CMAC-PID 控制,系统在维持相当长时间的稳定后,突然崩溃。通过仿真,对各个参数对不稳定的影响进行了分析,系统变为不稳定的原因,不是参数选取不当导致,不同的参数,只能改变系统变为不稳定的时间长短,不能从根本上克服系统变为不稳定,其根本原因是由原控制结构和算法导致的。为下一章中对原有控制方案进行改进提供了借鉴。

④ 第四章,针对传统的 CMAC-PID 控制结构由于 CMAC 和 PID 相互作用,产生过学习现象,导致系统不稳定,在原有控制结构基础上提出了一种改进方案。给出了改进型 CMAC-PID 控制器的控制结构和详细控制算法,通过仿真验证了改进方案的有效性。建立了火电厂应急柴油发电机组在 MATLAB SIMULINK 环境下的仿真模型,将改进型 CMAC-PID 控制器用于柴油发电机组的调速系统,通过仿真分析,验证了所建模型的正确性和应急柴油发电机组在改进型 CMAC-PID 控制下比常规 PID 控制下有更好的动态性能,转速(频率)瞬态调整率小,稳定时间短,克服了常规控制器所不能避免的一些弊端,提高了控制效果。

⑤ 第五章,对全文进行了总结,并指出了后续研究工作的重点。

2 神经网络控制

人工神经网络 (ANN) 作为动态系统辨识、建模和控制, 令人非常感兴趣, 在过去十多年中得到广泛的应用, 其中也包括在控制方面的应用。本章重点讨论神经控制的各种结构方案。

2.1 神经网络控制结构方案^{[12][13][14]}

迄今为止, 国内外已经提出十多种神经网络控制方案, 分类方法也很多, 本章主要讨论神经控制结构的典型方案包括 ANN 监督控制、ANN 自适应控制、ANN 直接逆控制、ANN 监督控制、ANN 内模控制、ANN 预测控制等。

2.1.1 ANN 监督控制

对于许多需要人参与的控制, 由于受控系统的动态特性是未知的或仅有部分已知, 用传统的控制技术去设计代替人的控制器, 使得系统能被有效的控制相当困难。由于神经网络具有逼近任意非线性函数的能力, 因此训练神经网络使其逼近从人的感观到人的决策输出的映射, 就可以获得代替人的神经网络控制器。通常称为基于神经网络的监督控制或学习控制。图 2.1 给出了一个 ANN 监督控制的结构, 图中包括一个导师 (监督程序) 和一个可训练的神经网络控制器 (NNC)。控制器的输入对应于由人接收 (收集) 的传感输入信息, 而用于训练的输出对应于人对系统的控制输入。这种控制的缺点是无反馈动力学。

实现 ANN 监督控制的步骤如下:

① 通过传感器和传感信息处理, 调用必要的和有用的控制信息。

② 构造神经网络, 选择 ANN 类型、结构参数和学习算法等。

③ 训练 ANN 控制器, 实现输入和输出间的映射, 以便进行正确的控制。在训练过程中, 可采用线性规律、反馈线性化或解耦变换的非线性反馈作为导师 (监督程序) 来训练 ANN 控制器。




图 2.1 ANN 监督控制

Fig 2.1 Supervisory control of ANN

2.1.2 ANN 直接逆模型控制

ANN 直接逆模型控制, 采用受控系统的一个逆模型, 串联在受控系统之前, 使期望相应(网络输入)与受控系统输出间得到一个相同的映射。因此, 该网络(ANN)直接作为前馈控制器, 而且受控系统的输出等于期望输出, 这种方法很大程度上依赖于作为控制器的逆模型的精确程度, 由于不存在反馈, 本法鲁棒性不足, 逆模型可以通过在线调整, 以期把受控系统的鲁棒性提高至一定高度。

图 2.2 给出了 ANN 直接逆控制的两种结构方案。在图 2.2 (a) 中, 网络 ANN1 和 ANN2 具有相同的逆模型网络结构, 而且采用相同的学习算法。图 2.2 (b) 为 ANN 直接逆控模型控制的另一种结构方案, 采用一个评价函数 (EF)。




图 2.2 ANN 直接逆控制

Fig 2.2 Direct inverse control of ANN

2.1.3 ANN 自适应控制

ANN 自适应控制与常规自适应控制一样, 也分为两类, 即自校正控制 (STC) 和模型参考自适应控制 (MRAC)。STC 和 MRAC 之间的差别在于: STC 根据受控系统的正和/或逆模型辨识结果直接调节控制器的内部参数, 以期能够满足系统给定的性能指标; 在 MRAC 中闭环控制系统的期望性能由一个稳定的参考模型描述, 而该模型又由输入-输出对 $\{r(t), y'(t)\}$ 确定的。本控制系统的目标在于使受控装置的输入 $y(t)$ 与参考模型的输出渐进的匹配, 即

$$\lim_{t \rightarrow \infty} \|y'(t) - y(t)\| \leq \varepsilon \quad (2.1)$$

式中, ε 为一指定常数。

① ANN 直接自校正控制 (STC)

该控制系统由一个常规控制器和一个具有离线辨识能力的识别器组成; 后者具有很高的建模精度。ANN 直接自校正控制的结构基本上与直接逆控制相同。

② ANN 间接自校正控制

本控制系统有一个神经网络控制器和一个能够在线修正的 ANN 识别器组, 图 2.3 表示出 ANN 间接 STC 的结构。




图 2.3 ANN 间接自校正控制

Fig 2.3 Indirect self-correction control of ANN

一般，通常假设受控对象（装置）为式 (2.2) 所示的单变量非线性系统。

$$y_{k+1} = f(y_k) + g(y_k)u_k \quad (2.2)$$

式中， $f(y_k)$ 和 $g(y_k)$ 为非线性函数。令 $\hat{f}(y_k)$ 和 $\hat{g}(y_k)$ 分别代表 $f(y_k)$ 和 $g(y_k)$ 的估计值，如果 $f(y_k)$ 和 $g(y_k)$ 是由神经网络离线辨识的，那么能够得到足够的近似精度的 $\hat{f}(y_k)$ 和 $\hat{g}(y_k)$ ，而且可以直接给出常规控制规律：

$$u_k = [y_{d,k+1} - \hat{f}(y_k)] / \hat{g}(y_k) \quad (2.3)$$

式中， $y_{d,k+1}$ 为 $k+1$ 时刻的期望输出。

③ ANN 直接模型参考自适应控制

ANN 直接模型参考自适应控制如图 2.4 所示，由图可知，ANN 直接模型参考自适应控制器力图维持受控对象输出与参考模型输出间的差

$e_c(t) = y(t) - y^m(t) \rightarrow 0$ 或 $e_c(t)$ 的二次型最小。由于反向传播需要知道受控对象的数学模型，因而该 ANN 控制器的学习和修正遇到很多问题。




图 2.4 ANN 直接模型参考自适应控制

Fig 2.4 Reference control direct control of ANN

④ ANN 间接模型参考自适应控制

控制结构如图 2.5 所示图中，ANN 识别器（NNI）首先离线辨识受控对象的前馈模型，然后 $e_c(t)$ 进行在线学习与修正。显然 NNI 能够提供误差 $e_c(t)$ 或其变化率的反向传播。

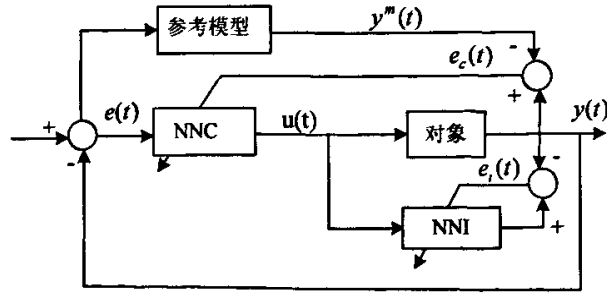


图 2.5 ANN 间接模型参考自适应控制

Fig 2.5 Reference control indirect control of ANN

2.1.4 ANN 内模控制

内模控制以其较强的鲁棒性和易于进行稳定性分析的特点，在过程控制中获得广泛的应用。Hunt 将其推广到非线性系统中，提出了图 2.6 所示的非线性系统的内模控制系统，其中被控对象的前向动态神经网络模型与被控对象相关联，将作为控制器的被控对象的逆动态模型串联在此之前，而在逆动态模型之前还串联了一线性滤波器，同时还将被控对象与其前向动态神经网络模型的输出之差作为负反馈信号，反馈到整个控制系统的输入端。此结构，对于线性系统，要求对象是开环稳定的，对于非线性系统，还有待研究。




图 2.6 ANN 内模控制

Fig 2.6 Internal mold control of ANN

2.1.5 ANN 预测控制

预测控制是 20 世纪 70 年代发展起来的一种新的控制算法，它是一种基于模型的控制，具有预测模型、滚动优化和反馈校正等特点。已经证明本方法有希望对非线性系统产生稳定作用。

图 2.7 表示 ANN 预测控制的一种结构方案，图中，神经网络预测器 NNP 为一神经网络模型，NLO 为一非线性优化器。NNP 预测受控对象在一定范围内的未来响应。通过设计优化性能指标，利用非线性优化器可以求出优化的控制作用 $u(t)$ 。

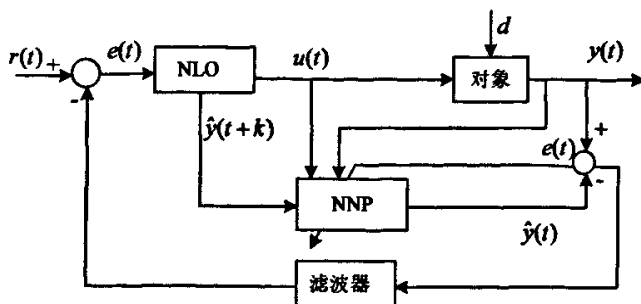


图 2.7 ANN 预测控制

Fig 2.7 Forecast control of ANN

2.1.6 多层 ANN 控制

多层神经网络控制器基本上是一种前馈控制器。考虑图 2.8 所示的一个普通的多层神经控制系统。该系统存在两个控制作用：前馈控制和常规反馈控制。前馈控制由神经网络实现；前馈部分训练的目标在于使期望输出与实际装置输出间的偏差为最小。该误差作为反馈控制器的输入。反馈作用于前馈作用被分别考虑，特别关注前馈控制其的训练而不考虑反馈控制的存在。已提出多层 ANN 控制器的三种结构：间接结构、通用结构还专用结构。




图 2.8 多层 ANN 控制的一般控制

Fig 2.8 Normal control structure of multi-layer ANN

① 间接学习结构




图 2.9 间接学习结构的多层 ANN 控制

Fig 2.9 Indirect control structure of multi-layer ANN

图 2.9 所示的间接多层 ANN 控制结构含有两个同样的神经网络，用于训练。在本结构中，没个网络作为一个逆动态辨识器。训练的目标是要从期望响应 d 中找到一个合适的装置控制 u 。以网络 I 和网络 II 间的差为基础来调整权值，使得误

差 e 为最小；如果能够训练网络 I 使得 $y = d$ ，那么， $u = u^*$ 。不过，这不能保证期望输出 d 与实际输出 y 之间的差别为最小。

② 通用学习结构




图 2.10 通用学习结构

Fig 2.10 General control structure

图 2.10 给出了多层 ANN 控制的通用学习结构，它使图 2.9 中的 $e = d - g$ 为最小。该网络被训练使得装置输入 u 与网络输出 u^* 间的差别为最小。在训练时， u 应当处在这样的范围内使得 y 覆盖期望输出 d 。训练之后，如果某一期望输出 d 被送至网络，那么该网络就能够为受控装置提供一个合适的 u 。本结构的局限性是：一般无法知道哪一个 u 对应于期望输出 d ，因而网络不得不在 u 的大范围内进行网络训练以求经过学习能够使装置输出 y 包括期望输出 d 。

③ 专用学习结构

多层 ANN 的专用学习结构如图 2.9 所示，当神经网络训练时，期望输出 d 与装置的实际输出 y 之间的差别 e 为最小。因此，不仅能够期望得到良好的装置输出，而且训练能够在期望输出范围内执行，而不需要知道装置的合适输入范围。不过本结构中把装置当作网络的一层处理。为了训练该网络，或者必须知道装置的动力学模型，或者必须进行某种近似处理。对多层神经网络控制器的训练是由误差反向传播算法来完成的。该误差可以期望输出与实际装置输出间的差，可以为校正装置输入与由神经网络计算得到的输入之间的差。




图 2.11 专用学习结构

Fig2.11 Special control structure

2.1.7 分级 ANN 控制

图 2.11 表示一种基于神经网络的分级控制器模型。图中， d 为受控装置的期

望输出, u 为装置的控制输入, y 为装置的实际输出, u^* 和 y^* 为由神经网络给出的装置的计算输入和输出。该系统可视为由三部分组成。第一部分为一常规外反馈回路。反馈控制以期望装置输出 d 与由传感器测量的实际装置输出 y 间的误差 e 为基础的, 即以 $e = d - y$ 为基础的。通常, 常规外反馈控制器为一比例微分控制器。第二部分是神经网络 I 连接的通道, 该网络为一受控对象的动力学内模型, 用于监控装置的输入 u 和输出 y , 且学习受控对象的动力学特性。当接收到装置的输入 u 时, 经过训练, 神经网络 I 能够提供一个近似的装置输出 y^* 。从这个意义上看, 这部分起到系统动态特性辨识器的作用。

以误差 $d - y^*$ 为基础, 这部分提供一个比外反馈回路快的多得内反馈回路, 因为外反馈回路一般在反馈通道上有传感滞后作用。系统的第三部分是神经网络 II, 它监控期望输出指令 d 和装置的输入 u 。这个神经网络学习建立装置的内动力学模型; 当它收到期望输出指令 d 时, 经过训练, 它能产生合适的装置输入分量 u^* 。该受控对象的分级神经网络模型按下列过程运作。传感反馈主要在学习阶段起作用, 此回路提供一个常规反馈信号去控制装置。由于传感延时作用和较小的可允许控制增益, 因而系统的响应较慢, 从而限制了学习阶段的速度。在学习阶段, 神经网络 I 学习系统的动力学特性, 而神经网络 II 学习逆动力学特性。随着学习的进行, 内反馈逐渐取代外反馈的作用, 成为主控制器。然后学习进一步进行时, 该逆动力学部分将取代内反馈控制。最后结果是, 该装置主要由前馈控制器进行控制, 因为装置的输出误差与内反馈一起几乎不复存在, 从而提供处理随机扰动的快速控制。在上述过程中, 控制与学习同步执行。两个神经网络起到辨识器的作用, 其中一个辨识装置动力学特性, 另一个辨识逆动力学特性。

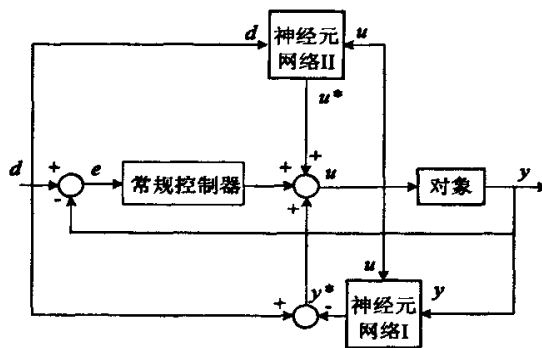


图 2.12 分级 ANN 控制器

Fig 2.12 Cascade ANN controller

基于分级神经网络的控制系统有下列特点:

- ① 该系统含有两个辨识器, 一个用于辨识装置的动力学特性, 另一个用于辨

识装置的逆动力学特性。

- ② 存在一个主反馈回路，它对训练神经网络是很重要的。
- ③ 当训练进行时，逆动力学部分变为主控制器。
- ④ 控制效果与前馈的效果相似。

上述的神经网络控制器的结构方案，除了具有共性外，还存在各自特点，适用于不同的应用领域，可以根据控制要求和应用要求选择适合具体应用的某种经典控制器。

2.2 一般神经网络控制的局限性

随着人工神经网络研究的进展，神经网络越来越多的应用于控制领域的各个方面。在系统的辨识、建模、自适应控制中特别受到重视，尤其较好的解决了具有不确定性、严重非线性、时变和滞后的复杂系统的建模和控制问题。但是不能不看到，在神经网络实际应用的同时，有关系统的稳定性、能控性、能观性等理论问题，有关人工神经网络控制系统优化设计方法问题，神经网络的拓扑结构问题，以及神经网络与基于规则系统有机结合的问题，还有待于进一步研究和发展，一般神经网络的弱点，制约了其在控制系统中的广泛应用，包括以下问题：

① 一般神经网络的收敛速度很慢，训练和学习时间很长，这是大多数控制系统所不能接受的。

② 一般神经网络的结构选取，特别是隐含层单元个数的选取尚无定则，还需要通过反复试验才能确定，这给实际应用带来困难。

③ 一般神经网络连接权初值多被取为随机数，存在陷入局部极小值的可能，使控制难以达到预期的效果；特别是由于连接权初值的随机性，很难保证控制系统初始运行的稳定性，而如果控制系统初始运行不稳定，失去了应用的基础。

④ 传统神经网络的结构、参数和机能，难以与控制系统所要求的响应快、超调小、无静差等动态和静态性能指标相联系。

⑤ 传统神经网络在构成控制器时，为了满足性能要求，大量增加隐含层神经元个数，网络的计算量很大，便在当前的技术水平下很难保证控制的实时性。

⑥ 具有任意函数逼近能力的多层前向神经网络是应用最多的一种神经网络但传统的多层前向神经网络的神经元仅具有静态输入—输出特性，在用它构成控制系统时必须附加其他动态部件。

2.3 PID 控制^[15]

2.3.1 PID 控制原理

PID 控制系统的结构如图 2.131 所示：




图 2.13 PID 控制系统原理框图

Fig 2.13 Control schematic diagram of PID

给定值 $r(t)$ 与实际输出值 $y(t)$ 构成控制偏差:

$$e(t) = r(t) - y(t) \quad (2.4)$$

将偏差 $e(t)$ 的比例 (P)、积分 (I) 和微分 (D) 通过线性组合构成控制量, 对被控对象进行控制, 其控制规律为:

$$\begin{aligned} u(t) &= K_p [e(t) + \frac{1}{T_i} \int_0^t e(t) dt + T_D \frac{de(t)}{dt}] \\ &= K_p e(t) + K_I \int_0^t e(t) dt + K_D \frac{de(t)}{dt} \end{aligned} \quad (2.5)$$

写成传递函数形式:

$$G(s) = \frac{U(s)}{E(s)} = K_p [1 + \frac{1}{T_i s} + T_D s] \quad (2.6)$$

式中, K_p —— 比例系数;

T_i —— 积分时间常数;

T_D —— 微分时间常数;

PID 控制器各校正环节的作用如下:

① 比例环节

即时成比例地反映控制系统的偏差信号 $e(t)$, 偏差一旦产生, 控制器立即产生控制作用, 以减少偏差。 K_p 越大超调越大。

② 积分环节

主要用于消除静差, 提高系统的无差度。积分作用的强弱取决于积分时间常数 T_i , T_i 越大, 积分作用越弱, 反之则越强。

③ 微分环节

能反映偏差信号的变化趋势 (变化速率), 并能在偏差信号值变得太大之前, 在系统中引入一个有效的早期修正信号, 从而加快系统的动作速度, 减少调节时间。

2.3.2 数字 PID 控制

计算机控制是一种采样控制，它只能根据采样时刻的偏差值计算控制量，因此模拟控制算法不能直接使用，需要采用离散化方法。在计算机控制中，使用的是数字 PID 控制器。

① 位置式 PID 控制算法

位置式 PID 控制表达式：

$$u(k) = K_p e(k) + K_I \sum_{j=0}^k e(j) + K_D [e(k) - e(k-1)] \quad (2.7)$$

式中 k —— 采样序号， $k=0, 1, 2, \dots$

$u(k)$ —— 第 k 次采样时刻的计算机输出值；

$e(k)$ —— 第 k 次采样时刻输入的偏差值；

$e(k-1)$ —— 第 $k-1$ 次采样时刻输入的偏差值；

K_I —— 积分系数， $K_I = K_p \frac{T}{T_I}$ ；

K_D —— 微分系数， $K_D = K_p \frac{T_D}{T}$ ；

图 2.14 给出了位置式 PID 控制系统示意图。




图 2.14 位置式 PID 控制系统

Fig 2.14 Position-type PID control system

这种算法缺点，由于全量输出，所以每次输出均与过去的状态有关，计算时要对 $e(k)$ 进行累加，计算机运算工作量大。因为计算机输出的 $u(k)$ 对应的是执行机构的实际位置，如计算机出现故障， $u(k)$ 的大幅度变化，会引起执行机构位置的大幅度变化，这种情况往往是生产实践中不允许的，在某些场合还可能造成重大的事故。

② 增量式 PID 算法

当执行机构需要的是控制量的增量（例如驱动步进电动机），可以采用增量式 PID 算法：

$$\begin{aligned} \Delta u(k) &= K_p [e(k) - e(k-1)] + K_I e(k) + K_D [e(k) - 2e(k-1) + e(k-2)] \\ &= K_p \Delta e(k) + K_I e(k) + K_D [\Delta e(k) - \Delta e(k-1)] \end{aligned} \quad (2.8)$$

式中 $\Delta e(k) = e(k) - e(k-1)$

图 2.15 给出了增量式 PID 控制示意图。




图 2.15 增量式 PID 控制系统

Fig 2.15 Incremental PID control system

采用增量式算法时，计算机输出的控制增量 $\Delta u(k)$ 对应的是本次执行机构（例如阀门开度）的增量。增量式控制虽然只是在算法上作了一点改进，却带来了不少优点：

由于计算机输出增量，所以误动作时影响小，必要时可以用逻辑判断的方法去掉。

1) 手动/自动切换时冲击小，便于实现无扰动切换。此外，当计算机发生故障时，由于输出通道或者执行装置具有信号的锁存作用，故仍能保持原值。

2) 算式中不需要累加。控制增量 $\Delta u(k)$ 的确定，仅与最近 k 次的采样值有关，以较容易通过加权处理而获得较好的控制效果。

但增量式控制也有其不足之处：积分截断效应大，有静态误差；溢出的影响大。一般认为在晶闸管作为执行器或者控制精度要求高的系统中，可采用位置控制算法，而在以步进电机或者电动阀门为执行器的系统中，则可采用增量式控制算法。

2.3.3 几种改进的 PID 算法

根据控制不同的控制对象，采用普通 PID 控制，效果有时不理想，因此出现了在普通 PID 基础上的几种改进控制算法。

① 积分分离 PID 控制算法

在普通 PID 控制中，引入积分环节的目的在于消除静差，提高控制精度。但在过程的启动、结束或大幅度增减设定时，短时间内系统输出有很大的偏差，会造成 PID 运算的积分积累，致使控制量超过执行机构可能允许的最大动作范围对应的极限控制量，引起系统较大的超调，甚至引起系统较大的震荡，这在生产中是绝对不允许的。

积分分离控制基本思想，当控制量与设定值偏差较大时，取消积分作用，以免由于积分作用使系统稳定性降低，超调量增大；当被控量接近给定值时，引入积分控制，以便消除静差，提高控制精度。控制算法如公式 2.9：

$$u(k) = K_p e(k) + \beta K_I \sum_{j=0}^k e(j)T + k_D (e(k) - e(k-1))/T \quad (2.9)$$

式中, T 为采样时间, β 为积分项的开关系数

$$\beta = \begin{cases} 1 & |e(k)| \leq \varepsilon \\ 0 & |e(k)| > \varepsilon \end{cases} \quad (2.10)$$

② 抗积分饱和 PID 控制算法

积分饱和现象是指若系统存在一个方向的偏差, PID 控制器的输出由于积分作用的不断累加而加大, 从而导致执行机构达到极限位置 (如阀门开度达到最大), 若控制器输出 $u(k)$ 继续增大, 阀门开度不可能再增大, 此时就称计算机输出控制量超出了正常运行范围而进入饱和区。一旦系统出现反向偏差, $u(k)$ 逐渐从饱和区退出。进入饱和区愈深则退出饱和区所需时间愈长。在这段时间内, 执行机构仍停留在极限位置而不能随偏差反向立即作出相应的改变, 这时系统就像失去控制一样, 造成控制性能恶化。这种现象称为积分饱和现象或积分失控现象。

抗积分饱和方法的思路是, 在计算 $u(k)$ 时先判断 $u(k-1)$ 是否已经超出限制范围。若 $u(k-1) > u_{\max}$, 则只需累加负偏差, 若 $u(k-1) < u_{\min}$, 则只需累加正偏差。这种算法可以避免控制量长时间停留在饱和区。

③ 带死区的 PID 控制算法

计算机控制系统中, 有些系统为了避免控制动作的过于频繁, 消除震荡, 可采用带死区的 PID 控制。相应的控制算法为:

$$e(k) = \begin{cases} 0 & \text{当 } |e(k)| \leq |e_0| \text{ 时} \\ e(k) & \text{当 } |e(k)| > |e_0| \text{ 时} \end{cases} \quad (2.11)$$

死区 e_0 是一个可调参数, 其具体的数值可根据实际控制对象由实验确定。带死区的 PID 控制结构图如图 5 所示。




图 2.16 带死区的 PID 控制系统框图

Fig 2.16 Control schematic diagram with dead zone

另外, 还有只对输出量进行微分, 而对给定值不微分的微分先行 PID 控制算法, 这种算法可以避免给定值升降时引起系统振荡, 改善动态性能; 在高精度伺服控制中, 还有采用基于前馈补偿的 PID 控制算法能够提高系统的跟踪性能。

2.4 本章小结

随着人工神经网络研究的深入，其应用范围也扩展到控制领域，本章重点讨论了神经网络控制的结构方案，包括 ANN 监督控制、ANN 自适应控制、ANN 直接逆控制、ANN 监督控制、ANN 内模控制、ANN 预测控制，给出了结构图，并分析其原理。同时指出，在神经网络实际应用的同时，有关系统的稳定性、能控性、能观性等理论问题，有关人工神经网络控制系统优化设计方法问题，神经网络的拓扑结构问题，还有待于进一步研究和发展，与当前非常成熟应用广泛的 PID 控制相结合，取长补短，在当前不失为一种很好的控方案。文中还对 PID 的机理作了论述。

3 神经网络与 PID 的复合控制

3.1 引言

前面绪论中所述, 由于人工神经网络在实际控制系统应用中, 还有很多问题没有解决, 需要进一步研究和发展。而 PID 控制方法, 从问世至今, 广泛应用于控制领域的各个方面, 是迄今为止最通用的控制方法, 但在 PID 控制中一个至关重要的问题就是 PID 参数(比例、积分和微分)的整定。而这些参数的整定困难使 PID 控制器的应用受到限制, 实际上 PID 控制规律是一种线性控制规律, 它也具有传统控制理论的弱点, 仅在简单的线性单变量系统中有良好的控制效果, 而在复杂系统的控制效果中控制效果不佳。如果将人工神经网络与 PID 控制相结合, 能很好解决参数整定难和参数自整定的问题, 取长补短, 能实现良好的控制效果, 是现阶段创造优良控制器的有效途径之一。实际上 2.1 节所述的神经网络控制器的多种结构方案中, 有几种都采用了一般神经网络与 PID 控制器相结合的结构, 如神经网络自校正控制、多层神经网络控制、分级神经网络控制等。

由于存在多种类型的神经网络, 因而神经网络与 PID 复合控制结构也有多种形式, 神经网络与 PID 复合控制方案可以分为 3 类: 基于单神经元网络的 PID 控制、基于神经网络在线整定 PID 参数的控制方案(基于 BP 神经网络的 PID 控制、基于 RBF 神经网络整定的 PID 控制等)和基于 CMAC 与 PID 的并行控制。

3.2 基于单神经元的 PID 控制方案

单神经元PID控制的控制框图如图3.1所示。




图3.1 单神经元PID控制器结构图

Fig 3.1 Control schematic diagram of nerve cell PID

图中转换器的输入为设定值 $y_d(k)$ 和输出 $y(k)$, 转换器的输出为神经元学习控制所需要的状态量 $x_1(k), x_2(k), x_3(k)$ 。其中

$$x_1(k) = y_d(k) - y(k) = e(k);$$

$$x_2(k) = e(k) - e(k-1);$$

$$x_3(k) = e(k) - 2e(k-1) + e(k-2)$$

$z(k) = x_1(k) = y_d(k) - y(k) = e(k)$ 为性能指标函数或递进信号。K 为神经元的比例系数，神经元通过关键搜索产生控制信号：

$$u(k) = u(k-1) + K \sum_{i=1}^3 w_i'(k) x_i(k) \quad (3.1)$$

$w_i(k)$ 对应于 $x_i(k)$ 的加权系数。

根据不同的学习规则可以产生不同的控制算法。

- (1) 采用由监督Hebb学习算法的单神经元自适应PID控制器。
- (2) 采用以输出误差二次方为性能指标的单神经元自适应PID控制器。
- (3) 采用以 $Pe^2(k+d) + Q\Delta u^2(k)$ 为性能指标的单神经元自适应控制器。

单神经元结构 PID 控制器的形式与传统 PID 控制器的形式是相同的，所不同的是传统 PID 控制器的比例、积分、微分是预先设定和固定不变的，而单神经元 PID 控制器的比例、积分和微分参数对应网络的连接权重值，是可按照算法改变的。虽然单神经元结构 PID 控制器的结构简单、容易实现，也具备单神经网络的一些优点，但它有本质性的弱点，这种网络类似于 F.Rosenblatt 在 20 世纪 60 年代初提出的单层感知机（Perception），这种单层网络只具备线性分类能力，甚至不能进行简单的异或运算，更不具备任意函数逼近能力，这种控制器在复杂系统的控制中难以达到良好的性能。本文也不予对它进行详细讨论。

3.3 基于神经网络在线调整 PID 参数的控制方案

这种方法的出发点是在传统的 PID 控制器的基础上附加一个或多个神经网络，利用神经网络的学习能力确定和调整 PID 参数，其结构如图 3.2 所示。




图 3.2 基于神经网络在线调整 PID 参数的控制方案

Fig 3.2 The control structure of tuning parameter online based on ANN

其中的神经网络 ANN 多采用全局学习神经网络，本文以应用最多的 BP 神经

网络为例进行研究。

3.3.1 BP神经网络的结构及特点^[16]

1986年, Rumelhart等提出了误差反向传播神经网络, 简称BP网络 (Back Propagation), 该网络是一种单向传播的前向网络。误差反向传播算法简称BP学习算法, 其基本思想是梯度下降法, 它采用梯度搜索技术, 以期使网络的实际输出值与期望输出值得误差均方根为最小。包含一个隐含层的BP神经网络的结构如图3.3所示, 其中 i 为输入层神经元, j 为隐含层神经元, k 为输出层神经元。




图3.3 三层BP神经网络结构

Fig 3.3 The structure of three-layer BP ANN

BP神经网络的特点:

- ① BP网络是一种多层网络, 包括输入层、隐含层和输出层;
- ② 层与层之间采用全互连方式, 同一神经元之间不连接;
- ③ 权值通过 δ 学习算法进行调节;
- ④ 神经元激发函数为S函数;
- ⑤ 学习算法由正向传播和反向传播组成;
- ⑥ 层与层的连接是单向的, 信息的传播是双向的;

3.3.2 BP-PID 控制器结构^{[17][18][19]}

PID控制要取得较好的控制效果, 就必须通过调整好比例、积分和微分三种控制作用, 形成控制量中即相互配合又相互制约的关系, 这种关系不是简单的“线性组合”, 而是从变化无穷的非线性组合中找出最佳的。神经网络所具有的任意非线性表达能力, 可以通过对系统性能的学习来实现具有最佳组合的PID控制。

基于BP神经网络的PID控制结构如图3.2所示, 其中的神经网络ANN为BP神经网络。

- ① 图中PID控制器对被控制对象进行直接控制。
- ② 神经网络的输出为PID控制器的三个参数 K_p 、 K_I 、 K_D , 通过对神经网络的自学习、加权系数调整, 使神经网络输出对应于最优控制规律下的PID控制参数。

3.3.3 控制算法

PID控制器一般采用经典PID控制算法：

$$\begin{cases} u(k) = u(k-1) + \Delta u(k) \\ \Delta u(k) = K_p(e(k) - e(k-1)) + K_I e(k) + K_D(e(k) - 2e(k-1) + e(k-2)) \end{cases} \quad (3.2)$$

式中， K_p 、 K_I 、 K_D 分别为比例、积分和微分系数。

BP神经网络若采用如图3.1所示的三层结构，隐含层神经元的输入为所有输入的加权之和，即

$$x_j^{(2)} = \sum_i^M w_{ij}^{(2)} x_i^{(1)} \quad (i=1,2,\dots,M) \quad (3.3)$$

式中，上标（1）、（2）分别代表输入层、隐含层，后续公式中出现的（3）代表输出层， M 表示输入层神经元的个数即输入变量的个数， M 的大小取决于被控系统的复杂程度。

隐层神经元的活化函数取S函数：

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (3.4)$$

则隐含层神经元的输出

$$y_j^{(2)} = f(x_j^{(2)}) \quad (3.5)$$

输出层神经元的输入为：

$$x_k^{(3)} = \sum_{j=0}^Q w_{jk}^{(3)} y_j^{(2)} \quad (3.6)$$

Q 为隐含层神经元的个数。

输出层神经元的活化函数取非负的S函数：

$$g(x) = \frac{e^x}{e^x + e^{-x}} \quad (3.7)$$

则输出层神经元的输出

$$y_k^{(3)} = g(x_k^{(3)}) \quad (k=1,2,3) \quad (3.8)$$

即

$$\begin{cases} y_1^{(3)} = K_p \\ y_2^{(3)} = K_I \\ y_3^{(3)} = K_D \end{cases} \quad (3.9)$$

$$\text{取性能指标函数 } E(k) = \frac{(r(k) - y(k))^2}{2} \quad (3.10)$$

则按照梯度下降法修正网络的权系数，若权值 w 的变化量记为 Δw ，则隐含层和输出层之间权值的改变量为：

$$\Delta w_{jk}^{(3)} = -\eta \frac{\partial E(k)}{\partial w_{jk}^{(3)}} + \alpha \Delta w_{jk}^{(3)}(k-1) \quad (3.11)$$

式中 η 为学习速率, α 为惯性系数。

$$\frac{\partial E(k)}{\partial w_{jk}^{(3)}} = \frac{\partial E(k)}{\partial y(k)} \cdot \frac{\partial y(k)}{\partial \Delta u(k)} \cdot \frac{\partial \Delta u(k)}{\partial y_k^{(3)}(k)} \cdot \frac{\partial y_k^{(3)}(k)}{\partial x_k^{(3)}(k)} \cdot \frac{\partial x_k^{(3)}(k)}{\partial w_{jk}^{(3)}(k)} \quad (3.12)$$

由公式(3.5)

$$\frac{\partial x_k^{(3)}(k)}{\partial w_{jk}^{(3)}(k)} = y_j^{(2)} \quad (3.13)$$

由于 $\frac{\partial y(k)}{\partial \Delta u(k)}$ 未知,可以用近似符号函数 $\text{sgn}\left(\frac{\partial y(k)}{\partial \Delta u(k)}\right)$ 取代,因为 $\frac{\partial y(k)}{\partial \Delta u(k)}$ 是权

值变化中的一个公共因子,最重要的是它的符号的正负,符号的正负决定着权值的变化方向,数值的大小只影响权值变化速度,由此带来计算不精确的影响,可以调整学习速率 η 来补偿。则输出层权值调整算法如下:

$$w_{jk}^{(3)}(k+1) = w_{jk}^{(3)}(k) + \eta \delta_k^{(3)} y_j^{(2)} + \alpha (w_{jk}^{(3)}(k) - w_{jk}^{(3)}(k-1)) \quad (3.14)$$

$$\text{其中 } \delta_k^{(3)} = e(k) \text{sgn}\left(\frac{\partial y(k)}{\partial \Delta u(k)}\right) \frac{\partial \Delta u(k)}{\partial y_k^{(3)}} \cdot g'(x_k^{(3)}(k)) \quad (k=1,2,3) \quad (3.15)$$

如同上面的分析,可得隐含层加权系数调整算法:

$$w_{ij}^{(2)}(k+1) = w_{ij}^{(2)}(k) + \eta \delta_j^{(2)} y_i^{(1)} + \alpha (w_{ij}^{(2)}(k) - w_{ij}^{(2)}(k-1)) \quad (3.16)$$

$$\delta_j^{(2)} = \sum_{k=1}^3 \delta_k^{(3)} w_{jk}^{(3)} \cdot f'(x_j^{(2)}(k)) \quad (j=1,2,\dots,Q) \quad (3.17)$$

基于BP神经网络的PID控制算法归纳如下:

- ① 确定BP网络的结构,选定学习速率 η ,给各层加权系数赋初值 $w_{ij}^{(2)}(0)$ 、 $w_{jk}^{(3)}(0)$, $k=1$;
- ② 对 $r(k)$ 和 $y(k)$ 进行采样,并计算实时误差 $e(k) = r(k) - y(k)$
- ③ 计算BP神经网络各层神经元的输入、输出,BP神经网络输出层的输出即为PID控制器的三个可调参数 K_P 、 K_I 、 K_D ;
- ④ 根据公式(2.7)计算PID控制器输出 $u(k)$;
- ⑤ 通过神经网络学习在线调整 $w_{ij}^{(2)}(k)$ 和 $w_{jk}^{(3)}(k)$,实现PID控制参数的自适应调整;

⑥ $k = k+1$,返回到①;

3.3.4 仿真比较分析

下面用MATLAB7.0对图3.2所示的BP神经网络PID控制结构进行仿真分析,设被控对象的数学模型为:

$$\begin{cases} y(k) = \frac{b(k)y(k-1)}{1+y^2(k-1)} + u(k-1) \\ b(k) = 1.9(1-0.8e^{-0.1k}) \end{cases} \quad (3.18)$$

① 跟踪阶跃响应

BP神经网络选取4-5-3的形式, $\eta=0.2$, $\alpha=0.05$, $t_s=0.001s$ 隐含层和输出层的初始权值为随机数。

为了验证这种控制结构的功效, 采用同样的控制对象用常规的PID进行控制。通过反复的调整验证确定PID的三个参数: 给定为阶跃信号时 $K_p=0.3$, $K_I=0.1$, $K_D=0.1$ 。

当输入为阶跃信号 $r=1$ 时, 基于BP神经网络PID控制下和单独的PID控制下输出曲线分别如图3.4和图3.5所示。纵坐标为给定信号 r 和输出信号 y , 横坐标为时间 t 。




图3.4 BP神经网络PID控制下阶跃跟踪曲线图

Fig 3.4 Step response under the control of BP-PID




图3.5 单独PID控制下阶跃跟踪曲线图

Fig 3.5 Step response under the control of single PID controller

对比图3.4和图3.5可以看出, 基于BP神经网络的PID控制在跟踪阶跃信号时,

超调量比单独PID控制时小，达到稳定的时间差不多，有良好的动态及静态特性。

图3.6为基于BP神经网络的PID控制下，输出层神经元的输出即PID的三个可调参数 K_p 、 K_i 、 K_d 的曲线图，可以看出经过学习计算，三个参数很快稳定在最优值。




图 3.6 BP神经网络PID控制跟踪阶跃时的输出参数图

Fig 3.6 The parameter of PID under the control of BP-PID

② 跟踪连续变化的正弦信号

当输入为连续变化的正弦信号 $r(t) = \sin(2\pi t)$ 时，基于BP神经网络PID控制下的输出曲线、误差曲线分别如图3.7—3.8所示。由图3.7-3.8可以看出，基于BP神经网络的PID控制在跟踪正弦信号时，一开始误差较大（第一周期），经过学习后很快就能跟踪给定信号，从误差曲线也可以定量的看出，稳定后每个周期的误差在2%以内。

图 3.9 为BP神经网络PID控制跟踪正弦信号时的输出参数图，由于神经网络的输出为PID的三个参数 K_p 、 K_i 和 K_d ，通过神经网络的学习，可以实现三个参数的在线调整，使参数达到最优，这也是常规PID所不能达到的功能。




图 3.7 BP神经网络PID控制跟踪正弦信号输出图

Fig 3.7 Sine signal response under the control of BP-PID




图 3.8 BP神经网络PID控制跟踪正弦信号误差曲线

Fig3.8 Error signal under the control of BP-PID




图 3.9 BP神经网络PID控制跟踪正弦信号时的输出参数图

Fig 3.9 The parameter of PID under the control of BP-PID

然而我们用常规PID控制器控制此非线性对象，跟踪正弦信号时，无论怎样调整PID的三个参数，都不能取得令人满意的控制效果。不是不能跟踪给定信号，就是发生振荡。例如，当 $K_p = 0.3$ ， $K_i = 0.01$ ， $K_d = 0.1$ 时，跟踪曲线如图3.10所示，不能跟踪给定信号。而把积分系数变大当 $K_p = 0.3$ ， $K_i = 0.1$ ， $K_d = 0.1$ 时，跟踪曲线如图3.11所示，有较大的振荡，输出误差大。




图 3.10 单独PID控制跟踪正弦信号输出图(1)

Fig 3.10 Sine signal response under the control of single PID(1)




图 3.11 单独PID控制跟踪正弦信号输出图(2)

Fig 3.11 Sine signal response under the control of single PID(2)

③ 跟踪方波信号

给定为1Hz的方波信号时，基于BP神经网络的PID控制的跟踪曲线图如图3.12所示，当跟踪方波信号从上升沿到下降沿时，这种控制结构具有明显的“反应迟钝”

性，超调量大，导致系统不稳定。出现这种现象的原因是BP神经网络固有的缺点导致的，BP神经网络主要缺点如下：

- ① BP神经网络是全局网络，收敛速度慢。
- ② 从数学上看，它是一个非线性优化问题，不可避免地存在局部极小的问题。
- ③ 网络中间层单元个数的选取尚无理论上的指导，而是根据经验选取。




图 3.12 基于BP神经网络的PID控制跟踪方波信号曲线图

Fig 3.12 Square wave response under the control of BP-PID

综上所述，基于BP神经网络与PID控制在跟踪阶跃信号、正弦信号时，都具有很好的动态特性和静态特性。通过学习，使神经网络输出对应于最优控制规律下的PID控制参数，比常规PID具有优势。但是在跟踪方波信号的上升沿到下降沿变化时，反应比较迟钝，跟踪误差大，不能达到实时控制要求。尽管BP网络算法有很多改进算法，如增加势态项、变步长法以及学习策略的改进等，但是都不能从根本上改变这种控制结构适应复杂环境下实时控制的要求。因此需要寻求更适合实时控制的神经网络和控制结构，达到复杂环境下实时控制的要求。

3.3.5 小结

分析了典型的神经网络—BP神经网络在线调整PID参数的控制方案，详细讨论了控制方案的控制机理，学习控制算法，仿真分析表明，在跟踪阶跃信号、正弦信号时，都具有很好的动态特性和静态特性。但是由于BP神经网络固有的缺点，在跟踪方波信号的上升沿到下降沿变化时，反应比较迟钝，跟踪误差大，不能满足实时控制要求。

3.4 CMAC 与 PID 的复合控制

CMAC (Cerebellar Model Articulation Controller) 神经网络是J.S.Albus 在1975

年最先提出来的,它是一种局部学习神经网络,能够学习任意多维非线性映射。相比其它神经网络(如BP神经网络)具有学习速度快,易于硬件、软件实现等特点,能有效用于非线性系统辨识和控制。Miller提出了一种CMAC与PID的复合控制结构并将其用于机器人的控制中,但是这种结构会存在不稳定现象。

3.4.1 Albus 提出的 CMAC 神经网络原理简介^{[20][21][22]}

CMAC是模拟人脑机能的人工神经网络,其基础来自Marr和Albus关于小脑功能的理论,CMAC的结构如图3.13所示,它由网络输入、概念映射(Conceptual Mapping)、物理映射(Physical Mapping)和网络输出四个基本部分组成。其输入状态空间 S 是一个多维空间,在图中, A_c 为概念存储单元, A_p 为物理存储单元, $F(s_i)$ 为CMAC神经网络的输出,输入状态空间中的每一个点都与概念存储空间 A_c 中的 C 个存储单元相对应,也与实际存储空间 A_p 中的 C 个单元相对应,而神经网络的输出 $F(s_i)$ 就是这 C 个单元中存储数值(网络权重)之和,由于对于每一输入样本都是对应于 A_c 和 A_p 上的 C 个单元,因而各样本分散存储于 A_c 和 A_p 中时,就有在输入空间中比较靠近的那些样本在 A_c 和 A_p 中出现交叠现象,这是CMAC神经网络的输出值也比较靠近,这种现象被称为CMAC神经网络的泛化能力

(Generalization)。这种泛化能力对于那些在输入空间中相距较远的矢量不起作用,CMAC神经网络的每一个输出为 A_p 中的 C 个存储单元的权重之线性叠加,整个CMAC神经网络不是全连接的,从输入空间 S 到 A_c 空间有 C 个连接,从物理空间 A_p 到输出也有 C 个连接,CMAC神经网络是三层网络,从输入空间到 A_c 为非线性映射,从 A_c 到 A_p 为随机散列映射,从 A_p 到输出为线性映射,而总的为非线性映射。

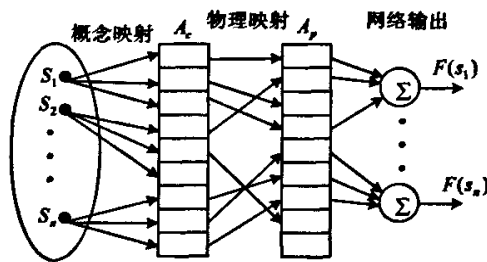


图 3.13 CAMC神经网络结构原理图

Fig 3.13 The schematic diagram of CMAC

3.4.2 从神经计算概念的角度定义CMAC^[23]

作为一种神经计算模型,CMAC可定义如下:

定义3.1 一个CMAC是一个表达映射 $P: U_{input} \rightarrow U_{output}$ 的计算模型, $U_{input} \subseteq R^n$ 和 $U_{output} \subseteq R^m$ 分别为CMAC的 n 维输入空间和 m 维输出空间, U_{input} 中的点记作 $x = (x_1, x_2, \dots, x_n)^T$; U_{output} 中的点记作 $o = (o_1, o_2, \dots, o_m)^T$ 。一个一般的CMAC是由 N

个感觉神经元和 H 个联想神经元以及 m 个反应神经元为元素构成的系统，可记作

$$ncm_{CMAC}^{(N \times H \times m)} = \{V_G, A_G, IF, OF, WA, OA\} \quad (3.19)$$

其中：

① 神经元集合 $V_G = \{S, A, R\}$

1) 感觉神经元集合 $S = \{S^{(k)} | k = 1, 2, \dots, n\}$

$S^{(k)}$ 为 $x_k \in x$ 的接收域，是量化 x_k 的感觉神经元子集，若令 N_k 为 x_k 的量化级数， $N_1 + N_2 + \dots + N_n = N$ ，则 $S^{(k)} = \{s_i^{(k)} | i = 1, 2, \dots, N_k\}$ ， $s_i^{(k)}$ 为 $S^{(k)}$ 中第 i 个感觉神经元， $o_k^{(S)}$ 为 $s_i^{(k)}$ 的输出， $b_k^{(S)}$ 为 $s_i^{(k)}$ 的量化阈值， $\bar{w}_k^{(S)}$ 为 $s_i^{(k)}$ 的量化宽度，满足

$$b_{k,j+1}^{(S)} \geq b_k^{(S)} + \bar{w}_k^{(S)} (i = 1, 2, \dots, N_k - 1) \quad (3.20)$$

2) 联想神经元集合 $A = \{a_i | i = 1, 2, \dots, H\}$

a_i 为 A 中第 i 个神经元，其输出 $o_i^{(A)}$ ，阈值 $b_i^{(A)} \equiv n$ ；对 A 进行适当排序，将 a_i 标记为 a_{i_1, i_2, \dots, i_n} ，则 A 可记作 $A = \{a_{i_1, i_2, \dots, i_n} | i_k = 1, 2, \dots, H_k; k = 1, 2, \dots, n\}$ ， a_{i_1, i_2, \dots, i_n} 的输出记作 $o_{i_1, i_2, \dots, i_n}^{(A)}$ ，阈值记作 $b_{i_1, i_2, \dots, i_n}^{(A)}$ ，其中， i_k 标记 $x_k (\in x)$ 的量化等级，成立：

$$\begin{cases} H_k = IC_k \times N_k + GC_k (k = 1, 2, \dots, n) \\ H = H_1 \times H_2 \times \dots \times H_n \end{cases} \quad (3.21)$$

其中， $IC_k (\geq 1)$ 是 x_k 的独立常数， $GC_k (\geq 0)$ 是 x_k 的泛化常数，而 $FC_k = IC_k + GC_k$ 是 $S^{(k)}$ 中感觉神经元 $s_i^{(k)}$ 的激发宽度。

3) 反应神经元集合 $R = \{r_i | i = 1, 2, \dots, M = m\}$

r_i 为 R 中第 i 个神经元，其输出 $o_i^{(R)} \in o$ 。

② 联结关系 $A_G = \{A_G^{(S)}, A_G^{(A)}, A_G^{(R)}\}$

1) 联结关系 $A_G^{(S)}: U_{input} \rightarrow S$

x_k 只与 $S^{(k)}$ 中的感觉神经元连结， $A_G^{(S)} = \{A_{Gk}^{(S)} | k = 1, 2, \dots, n\}$ ， $A_{Gk}^{(S)}$ 为 $x_k \rightarrow S^{(k)}$ 的连接关系，若将 $x_k \rightarrow s_i^{(k)}$ 的联结强度记作 $w_{ki}^{(S)}$ ，则

$$A_{Gk}^{(S)} = (w_{k1}^{(S)} \ w_{k2}^{(S)} \ \dots \ w_{kN_k}^{(S)}) = \underbrace{(1 \ 1 \ \dots \ 1)}_{N_k} (k = 1, 2, \dots, n) \quad (3.22)$$

2) 联结关系 $A_G^{(A)}: S \rightarrow A$

若将 $s_i^{(k)} \rightarrow a_{i_1, i_2, \dots, i_n}$ 的联结强度记作 $w_{ki|i_1, i_2, \dots, i_n}^{(A)}$ ，则

$$\begin{cases} A_{Gk}^{(A)} = \left\{ w_{ki|i_1, i_2, \dots, i_n}^{(A)} \middle| \begin{array}{l} i = 1, 2, \dots, N_k; i_k = 1, 2, \dots, H_k \\ k = 1, 2, \dots, n \end{array} \right\} \\ w_{ki|i_1, i_2, \dots, i_n}^{(A)} = \begin{cases} 1 & IC_k \times (i-1) < i_k \leq IC_k \times i + GC_k \\ 0 & \text{其它} \end{cases} \end{cases} \quad (3.23)$$

3) 联结关系 $A_G^{(R)}: A \rightarrow R$

若将 $v_{i_1, i_2, \dots, i_n}^{(A)} \rightarrow v_j^{(R)}$ 的联结强度记作 $w_{i_1, i_2, \dots, i_n, j}^{(R)}$ ，则

$$A_G^{(R)} = \left\{ w_{i_1 i_2 \dots i_n}^{(j)} \left| \begin{array}{l} i_k = 1, 2, \dots, H_k; j = 1, 2, \dots, m \\ k = 1, 2, \dots, n \end{array} \right. \right\} \quad (3.24)$$

适当排序, 可将联结关系 $A_G^{(R)}$ 描述为

$$\begin{aligned} A_G^{(R)} &= \left\{ w_i^{(j)} \left| i_k = 1, 2, \dots, H; j = 1, 2, \dots, m \right. \right\} \\ &= W^{(R)} = (w^{(1)} \ w^{(2)} \ \dots \ w^{(m)}) \end{aligned} \quad (3.25)$$

$$w^{(j)} = (w_1^{(j)} \ w_2^{(j)} \ \dots \ w_H^{(j)})^T \ (j = 1, 2, \dots, m) \quad (3.26)$$

③ 输入域 $IF = S$

$s_i^{(k)} \in S$ 接收信号 $x_k \ (k = 1, 2, \dots, n)$

④ 输出域 $OF = R$

$r_i \in R$ 发送信号 $o_i^{(R)} \ (i = 1, 2, \dots, m)$

⑤ 工作算法WA

1) 感觉 (量化)

2) 概念映射 ($S \rightarrow A$)

3) 实际 (物理) 映射 ($A \rightarrow R$)

3.4.3 CMAC 模型的结构解析

根据定义CMAC的模型网络结构如图3.15所示。从结构上看, CMAC类似神经网络中的反射弧, 其中:

传入神经: CMAC感觉神经元 $s_i \ (i = 1, 2, \dots, N)$ 及其联结。

神经中枢: CMAC联想神经元 $a_i \ (i = 1, 2, \dots, H)$ 及其联结。

传出神经: CMAC反应神经元 $r_i \ (i = 1, 2, \dots, M)$ 及其联结。

从图3.14和式 (3.20) 可知, CMAC模型中, 感觉神经元 S 对输入向量 x 进行量化, 而子集 $S^{(k)} \in S \ (k = 1, 2, \dots, n)$ 的 N_k 个感觉神经元 $s_i^{(k)} \ (i = 1, 2, \dots, N_k)$ 对 $x_k \in x$ 进行量化, 将其划分为 N_k 个等级, 如果 t 时刻的输入 $x_k(t)$ 属于第 j 个量化级别, 则 $s_j^{(k)}$ 的输出 $o_j^{(S)}(t) = 1$, 而其余的感觉神经元 $s_i^{(k)} \ (i \neq j)$ 的输出值 $o_i^{(S)}(t) = 0$ 。对于任意时刻 t , $S^{(k)}$ 中有且只有一个感觉神经元的输出值为1, 而其余的为0。对于任意时刻 t , S 中有且只有 n 个感觉神经元的输出值为1。

图3.15所示的CMAC模型中, 联想神经元 A 接收来自感觉神经元层 S 的信号。由式 (3.21) 可知, 每个感觉神经元 $s_i^{(k)}$ 将联结到 $FC_k \times H / H_k$ 个联想神经元, 而每一个联想神经元 $a_{i_1 i_2 \dots i_n}$ 的阈值 $a_{i_1 i_2 \dots i_n}^{(A)} = n$ (输入空间维数), 一旦 $a_{i_1 i_2 \dots i_n}$ 受到 $\geq n$ 个兴奋得感觉神经元刺激, 其输出 $o_{i_1 i_2 \dots i_n}^{(A)} = 1$, 否则 $o_{i_1 i_2 \dots i_n}^{(A)} = 0$ 。

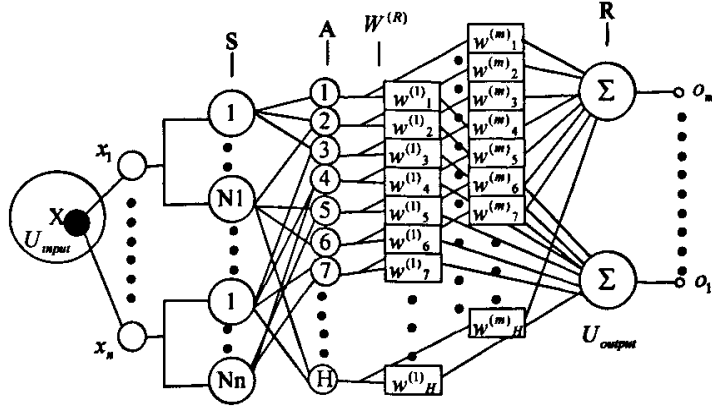


图 3.14 CMAC模型的网络结构

Fig 3.14 The network configuration of CMAC model

观察图3.15可知 $A \rightarrow R$ 的联结关系构成了CMAC模型的存储器，其中，共有 mH 个存储单元 $w^{(j)}_i (i=1,2,\dots,H; j=1,2,\dots,m)$ ，而联想单元集合 A 就是存储器 $W^{(R)}$ 的地址，其中，共有 H 个地址码 $a_i (i=1,2,\dots,H)$ ，每一个地址码 a_i 指向 m 个存储单元，分别存放着联想神经元 a_i 至反应神经元 $r_j (j=1,2,\dots,m)$ 的联想强度值。

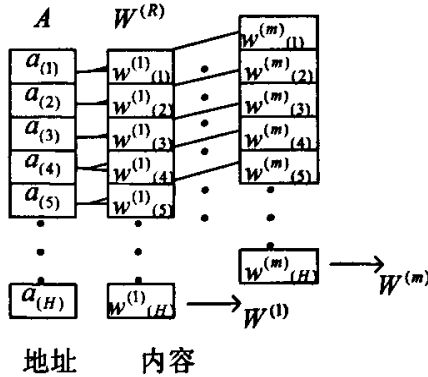


图 3.15 CMAC模型中的存储器

Fig 3.15 The memory of the CMAC

$S \rightarrow A$ 的过程，即CMAC模型由感觉神经元映射至联想神经元的过程，是一个寻址过程，输出值为1的联想神经元代表着被选中的存储单元。对于任意时刻，CMAC模型中被激发的联想神经元或被选中的存储器单元数为 $FC_1 \times FC_2 \times \dots \times FC_n$ 。

3.4.4 概念映射算法

CMAC神经网络本质上是一种查表方法，而映射和存储是它的关键作的好，既可节省空间又可节省时间，文献[24]给出了一种小脑模型的概念映射算法，但是其一维，二维和多维分别采用不同的公式，实际应用中比较麻烦。本文从上面

几节对CMAC体系结构分析的基础上,推导了CMAC概念映射算法的一般公式,这个公式不仅适用于一维、二维,也同样适用于多维输入和多维输出的情况。对于具有多个输出的系统,可以拆分为多个独立的输出系统,因此我们以单输出为例。

设CMAC为 n 维输入,每一输入的量化等级为 $N_k (k=1,2,\dots,n)$,联想存储空间中的地址 $a_i (i=1,2,\dots,H)$,对地址元素进行重新排序:

$a_i = a_{h_1, h_2, \dots, h_n} (k=1,2,\dots,n; h_k=1,2,\dots,H_k)$ 其中 H 和 H_k 由式(3.21)确定,分别表示联想存储空间中地址的总数和 k 维输入上面的地址个数。

$$\begin{cases} H_k = IC_k \times N_k + GC_k (k=1,2,\dots,n) \\ H = H_1 \times H_2 \times \dots \times H_n \end{cases} \quad (3.27)$$

其中, $IC_k (\geq 1)$ 是 x_k 的独立常数, $GC_k (\geq 0)$ 是 x_k 的泛化常数。设 i_k 为 x_k 在 t 时刻的量化值,则 t 时刻输入向量在联想空间单元 A 中映射的地址

$$A^* = \left\{ a_{h_1, h_2, \dots, h_n} \mid \begin{matrix} IC_k \times (i_k - 1) < h_k \leq IC_k \times i_k + GC_k \\ k=1,2,\dots,n \end{matrix} \right\} \quad (3.28)$$

下面以二维为例,说明该映射算法。

$x_1 \in [0,1], x_2 \in [0,1]$ 为二维CMAC模型输入,设量化等级 $N_1 = N_2 = 5$,独立常数 $IC_1 = IC_2 = 1$,泛化参数 $GC_1 = GC_2 = 3$ 。由式(3.21)得, $H_1 = H_2 = 8$,联想单元集合 A 中共有 $H = H_1 \times H_2 = 64$ 个单元。

映射如图3.17所示,例如当输入 $x_1 = 0.3, x_2 = 0.5$ 时,其量化值 $i_1 = 2, i_2 = 3$,根据公式(3.28), $1 < h_1 \leq 5, 2 < h_2 \leq 6$,则输入在图3.16联想单元集合 A 中的映射地址为 $A^* = \{a_{h_1, h_2} \mid h_1 = 2,3,4,5; h_2 = 3,4,5,6\}$,即图中深色的区域。




图 3.16 二维输入概念映射图例

Fig 3.16 The graphic example of two-dimension input

3.4.5 CMAC 的物理存储器与散列编码

图3.15所示的 $W^{(R)}(A)$ 是CMAC模型的虚拟存储器。对于 $m=1$ 的情况,假设CMAC输入向量 $x \in R^n$ 中每一个标量 $x_k (k=1,2,\dots,n)$ 的量化级别 N_k 均为 \bar{N} ,则由式(3.21)可知 $H_k \geq N_k$ 。则CMAC模型虚拟存储器 $w(A)$ 中至少包含 $H = \bar{N}^n$ 个存储单元。一个实数 x 一般需要30个以上的量化等级,对于一个十维实域输入空间,CMAC需要至少 $H = 30^{10}$ 个存储单元。

如此巨大的存储器无疑很大实现,在实际应用中, A 中被激励的联想神经元是稀疏的,可以采用散列编码(Hash Coding)技术,将 $W^{(R)}(A)$ 压缩到一个较小的空间中去。我们将易于物理实现的存储器称为物理存储器,并记作 $W_p^{(R)}(A_p)$, A_p 为物理地址, $W_p^{(R)}$ 对应 A_p 的存储内容。

散列编码技术是一种压缩计算机记忆容量的技术,用以处理稀疏数据的存储问题。所谓稀疏数据,指量小但散布在极广泛存储空间的数据,最典型的就是稀疏矩阵,实际上散列编码就是对稀疏数据地址的重排,将数据在稀疏空间或虚拟存储空间 $W^{(R)}(A)$ 中的地址映射到物理存储空间 $W_p^{(R)}(A_p)$,即 $A \rightarrow A_p$ 。对于CMAC模型,任意联想单元 $a_i \in A$ 的下标 i 是数据 w_i 在虚拟存储空间 $W^{(R)}(A)$ 中的地址,可作为散列编码程序的独立变量,计算出虚拟地址 i 在物理存储空间 $W_p^{(R)}(A_p)$ 中的地址副本,即物理地址 i_p 。实际上物理存储空间 $W_p^{(R)}(A_p)$ 可以比虚拟存储空间 $W^{(R)}(A)$ 小若干数量级,因此 $A \rightarrow A_p$ 是一个多对少的映射。

值得注意的是,散列映射只是一种解决CMAC模型实现问题的方法,一项解决CMAC模型存储空间 $W^{(R)}(A)$ 可能过大的问题的技术,并非CMAC模型的固有的或本质的部分,并且散列技术未必有充分的神经生理学的依据。实际上,随着电子技术和生物技术的发展,CMAC模型的计算速度和存储容量问题将逐渐消失,在未来的CMAC模型中无需散列映射也能实现。

3.4.6 传统的CMAC与PID复合控制方案^{[26]-[34]}

Miller在Albus提出的小脑模型控制器基础上,提出了CMAC与PID复合控制器,其结构如图3.18所示。该系统通过CMAC与PID的复合控制实现前馈反馈控制。

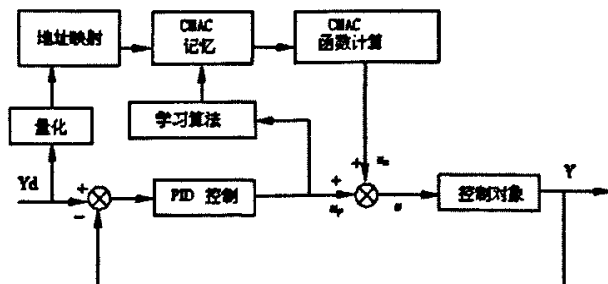


图3.17 传统CMAC与PID复合控制结构

Fig 3.17 Conventioanl CMAC-PID compound control scheme

在这种结构中,CMAC控制器实现前馈控制,实现被控对象的逆动态模型,常规控制器实现反馈控制,保证系统的稳定性,且抑制扰动。其工作可分为控制和学习两个过程,初始状态CMAC存储单元中的权值设为0,控制时,将下一周期的期望值 $Y(d+1)$ 量化后,作为地址输入到CMAC,在CMAC的联想单元集中找到与之对应的 C 个地址,并将 C 个地址中的权值相加得到CMAC的输出 u_n ,

$$u_n(k) = \sum_{i=1}^C w_i a_i \quad (3.29)$$

a_i 为二进制选择向量, C 为泛化参数。

然后将CMAC的输出与PID控制器的输出 u_p 相加,得到系统的总输入 u

$$u = u_n + u_p \quad (3.30)$$

在学习过程,通过比较控制总输入 u 和CMAC输出 u_n ,修正权值。学习的目的是使总控制输入与CMAC的输出之差最小,则控制主要CMAC产生。学习算法如下

$$\begin{cases} E(k) = \frac{1}{2} (u_n(k) - u(k))^2 \cdot \frac{a_i}{c} \\ \Delta w(k) = \eta \frac{u(k) - u_n(k)}{c} a_i \\ w(k) = w(k-1) + \Delta w(k) + \alpha (w(k) - w(k-1)) \end{cases} \quad (3.31)$$

式中, η 为学习速度, α 为惯性常数。

3.4.7 传统CMAC与PID复合控制的缺陷

这种控制结构虽然得到了一定的应用,但Chen和Chang通过控制一个非线性模型发现,在跟踪连续信号时尽管控制一开始,CMAC能够很好的跟踪误差,但是随着时间的增大,系统可能变得不稳定。

公式(3.32)为文献[35]提出的导致系统不稳定的非线性模型

$$Y(k+1) = 0.5Y(k) + \sin(y(k)) + U(k) \quad (3.32)$$

其中, $Y(k)$ 为系统输出, $U(k)$ 为系统控制总输入, $Y(k+1)$ 为下一次的期望输出。我们在MATLAB7.0环境下,对其进行仿真,CMAC的输入为 $(Y_{d+1}(k), Y(k))$,输出为 $U_n(k)$ 。由于此模型比较简单,PID控制器取为比例控制器,也能更好的验证整个控制器的性能。

仿真参数如下:

学习速率 $\eta = 0.2$;

量化参数 $q = 5/500$;

泛化参数 $c = 50$;

比例增益 $k_p = 1.4$;

参考信号 $Y_d(k) = \sin(2\pi kt)$;

当学习时间 $t = 5s$ 时, 跟踪曲线、系统误差曲线和各控制器的输出曲线分别如图3.18—图3.20所示。




图3.18 $t = 5s$ 时跟踪曲线

Fig 3.18 The tracing curve when $t = 5s$




图 3.19 $t = 5s$ 的误差曲线

Fig 3.19 The error curve $t = 5s$




图3.20 $t = 5s$ 时各控制器输出曲线

Fig 3.20 The output curve of controllers $t = 5s$

CMAC控制器在 $t = 1s$ 时加入,从图3.19和图3.20可以看出,输出迅速跟踪给定,在短时间内输出误差最大值由单独PID控制时的0.7减小到0.05,充分体现了CMAC学习速度快的特点。图3.20还可以看出CMAC加入后,PID控制器的输出迅速减小,CMAC控制器起主要作用,这是由式(3.31)所示的学习算法决定的,学习的目的就是为了使控制总输入 u 由CMAC产生。

在参数不改变的情况下,增加学习时间到 $40s$,系统跟踪曲线和误差曲线以及控制器输出曲线如图3.21和图3.23所示。可以发现,经过“相当长”的稳定学习,当学习时间快达到 $40s$ 时,输出 Y 不能跟踪给定 Y_d ,误差以及各控制器输出突然变大,导致了系统的不稳定或崩溃。。




图 3.21 $t = 40s$ 时的跟踪误差曲线

Fig 3.21 The error curve $t = 40s$





图3.22 $t = 40s$ 时的控制输出曲线

Fig 3.22 The output curve of controllers $t = 40s$

图3.23 $t = 40s$ 时的控制输出曲线Fig 3.23 The output curve of controllers $t = 40s$

3.4.8 参数对系统不稳定的影响

正如前面所述,加入CMAC后可以显著的提高非线性控制系统的性能,但是只能维持一段时间,系统会突然变的不稳定。本节还是针对如图3.18所示的传统CMAC-PID控制结构进行研究,分析各种参数(比例系数 k_p ,学习速率 η ,泛化参数 c)对系统不稳定的影响。为了分析各个参数对系统不稳定产生的影响,在仿真研究一个参数时,其它的参数保持不变。

仿真参数如下:

学习速率 $\eta = 0.2$;

量化参数 $q = 5/500$;

泛化参数 $c = 50$;

比例增益 $k_p = 1.4$;

① PID控制器的比例系数 k_p 的影响

只改变比例系数 k_p ,仿真结果如表3.1所示。其中 k_p 表示PID控制器的比例参数 e_p 表示单独PID控制(只有比例)时每个周期中的最大输出误差, e_c 表示CMAC-PID复合控制时周期最大输出误差的最小值。 t_u 表示系统变为不稳定的时间。

表3.1 k_p 的影响Table 3.1 The effect of k_p

k_p	0.4	0.6	0.8	1.0	1.2	1.4	1.6	1.8
e_p	0.8714	0.5800	0.4343	0.3469	0.2888	0.2473	0.2162	0.1921
e_c	0.0163	0.0149	0.0132	0.0141	0.0139	0.0135	0.0152	0.0138
$t_u(s)$	152	101	87	63	45	37	24	15

从表3.1可以看出：

- 1) 比例系数 k_p 越大， e_p 越小。
- 2) e_c 的值基本稳定在0.015左右，不随着 k_p 的变化而变化，从这里也可以知道，这种控制结构中，PID控制器不是起主要控制作用，真正的主控制器为CMAC。
- 3) 比例系数 k_p 越小，系统变不稳定的时间 t_u 越长。

② 学习速率 η 的影响

只改变学习速率 η ，仿真结果如表3.2所示。

表3.2 学习速率 η 的影响Table 3.2 The effect of learning rate η

η	0.8	0.4	0.2	0.02	0.002
e_c	0.0182	0.0211	0.0135	0.0176	0.0122
$t_u(s)$	6	23	37	54	124

从表3.2可以看出，学习速率 η 的大小不能改变系统变为不稳定的趋势，学习速率越大，系统变为不稳定的时间越小，即系统经过较少的时间就会变得不稳定。

③ 泛化参数 C 的影响

只改变泛化参数 C ，仿真结果如表3.3所示。

表3.3 泛化参数 C 的影响Table 3.3 The effect of generalization parameter C

C	30	50	70	100	200
$t_u(s)$	16	37	49	62	122

从表中可以看出泛化参数越大，变为不稳定的时间 t_u 越长，从一个角度讲泛化参数越大，就会降低学习速率，因此学习速率是影响系统不稳定的重要因素。

通过上面的分析我们知道，系统变为不稳定的原因，不是参数选取不当导致，

不同的参数，只能改变系统变为不稳定的时间长短，不能从根本上克服系统变为不稳定。系统变为不稳定是由原控制结构和算法导致的。

为更深入分析一下系统变为不稳定的原因，我们把图3.22中 u_n 和 u_p 曲线放大，如图3.24-图3.26分别是系统运行开始（6~7s）、中间（16~17s）以及变为不稳定前的两个周期（35~37s），PID控制器的输出 u_p 和CMAC的输出 u_n 的曲线。可以看出 u_n 以及 u_p 有振荡，一开始振荡小，随着时间的增加振荡幅度也慢慢变大，最终导致了系统的不稳定。这种过学习现象的产生，是由于图3.17所示的传CMAC-PID控制器中，CMAC与PID控制在学习过程中相互冲突导致的。




图 3.24 第7和第8个周期的 u_n 和 u_p 曲线图

Fig 3.24 The no.7 and no.8 circle curve of u_n and u_p





图 3.25 第17和第18个周期的 u_n 和 u_p 曲线图

Fig 3.25 The no.17 and no.18 circle curve of u_n and u_p

图 3.26 不稳定前两个周期的 u_n 和 u_p 曲线图Fig 3.26 The last two circle curve of u_n 和 u_p before unstable

3.4.9 小结

CMAC与PID的复合控制,能充分发挥小脑模型神经网络(CMAC)学习速度快,能逼近任意非线性函数的优势,PID控制器起辅助作用,CMAC控制器起主要控制作用。传统的CMAC-PID控制器在跟踪连续变化信号时,容易维持相当长的稳定时间后使系统变得不稳定,文中对各个参数对系统不稳定的影响进行了仿真分析,学习速率是影响系统不稳定的重要因素,学习速率越大,系统变为不稳定的时间越短。同时重要的一点,系统输出误差 not 随着PID控制器的比例系数 k_p 的变化而变化,而是稳定在一个小范围内,也就是说设计CMAC-PID控制器时,PID的参数选取不需要精心的选取,只要在合理的范围内即可,为实际应用带来方便。

3.5 本章小结

本章研究了神经网络与PID复合控制的三种控制方案。基于单神经元的PID控制,由于其单层网络只具备线性分类能力,甚至不能进行简单的异或运算,更不具备任意函数逼近能力,这种控制器在复杂系统的控制中难以达到良好的性能。在神经网络在线调整PID参数的控制方案中,神经网络可以在线学习,使PID的参数能够在线调整达到最优,但是神经网络一般采用全局学习的神经网络(BP),全局神经网络具有学习速度慢,容易陷入局部极小的缺点,因此这种控制在实时性要求高的场合不适用。文中对BP神经网络PID控制,通过一仿真实例,结果显示在跟踪方波信号的上升沿到下降沿变化时,反应比较迟钝,跟踪误差大,不能满足实时控制要求。

深入分析了小脑模型控制器(CMAC)的体系结构和运行机制,在此基础上,

推导了一种易于软件实现的，适用于一维到多维输入的概念映射算法。传统的CMAC-PID控制，系统在维持相当长时间的稳定后，突然崩溃。通过仿真，对各个参数对不稳定的影响进行了分析，系统变为不稳定的原因，不是参数选取不当导致，不同的参数，只能改变系统变为不稳定的时间长短，不能从根本上克服系统变为不稳定，其根本原因是由原控制结构和算法导致的。为下一章中对原有控制方案进行改进提供了借鉴。

4 改进型 CMAC-PID 控制器及其在柴油发电机组调速系统中的应用

对于柴油发电机组而言,发动机调速系统性能的好坏是决定整个发电机组电气性能(如:频率特性、电压特性及带载能力等)的关键。柴油发电机组的实时性和非线性非常突出,随转速、负荷及其它运动条件的变化,模型参数将发生很大的变化,这时调速系统采用 PID 控制器不足以补偿参数变化给系统带来的影响^[38],针对常规 PID 控制算法,参数整定难、不能实时调整参数和适应复杂、非线性环境差的缺点,提出了改进型 CMAC-PID 控制方案,克服了前面出现的不稳定现象,并将其用于自动化柴油发电机组的调速系统,提高控制性能。

4.1 改进型 CMAC-PID 控制方案

4.1.1 控制结构

针对原有CMAC-PID复合控制结构存在可能经过很长的稳定时间,最后使系统产生振荡,导致不稳定的缺点。文献[35]曾提出增加死区的方法来解决,但是增加了死区,系统就不能及时对参考输入的改变作出反应。本文在原有控制方案的基础上进行了改进,通过前一章的论述可知,传统CMAC-PID控制器之所以会使系统变得不稳定,最根本的原因就是CMAC与PID相互作用,产生了过学习现象,随着学习次数的增大,最终导致了系统不稳定。

改进后的控制结构图如图4.1所示,与原结构不同的地方在于原结构采用PID控制器的输出 $u_p(k)$ ($u_p(k) = u(k) - u_n(k)$)为调整权值学习的训练信号,CMAC学习的是被控对象的逆动态模型。基于此考虑,改进型CMAC-PID控制结构采用系统的跟踪误差 $e(k)$ ($e(k) = Y_d(k) - Y(k)$)作为调整权值学习的训练信号。这样,CMAC实现的不仅是被控制对象的逆动态模型,而且是包含了常规PID控制器在内的整个系统的逆动态模型,可以有效的消除传统的控制结构中,由于PID控制器和CMAC在学习产生冲突,导致系统不稳定的现象,另外在学习算法中,采用了变学习速率的方法,使系统在学习过程中能动态的调整学习速率,增强了自适应性。

另外,原控制器主要针对机器人的轨迹跟踪问题而设计,在跟踪方波和阶跃这类设定值较恒定的跟踪问题。CMAC的局部联想特性使得网络中存储的大部分信息被浪费,前馈控制抗干扰能力也差,因此改进型方案中采用的是将系统状态向量 $Y(k-1)$ 引入CMAC的输入空间。

图中CMAC的输入为 $(Y_d(k), Y(k-1))$, $Y_d(k)$ 给定信号, $Y(k-1)$ 为输出信号,CMAC为二维输入,CMAC的输出 $u_n(k)$ 和PID控制的输出 $u_p(k)$ 之和产生被控

对象的控制总输入 $u(k)$ ，CMAC通过学习，调整CMAC联想存储单元（存储器）中权值的大小，CMAC成为系统地逆动态模型，学习的目的使系统误差 $e(k)$ 最小。

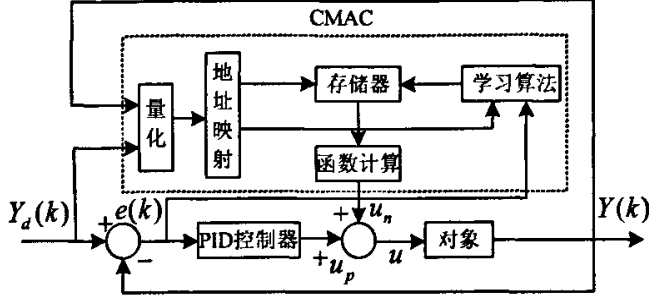


图 4.1 改进型 CMAC-PID 控制器

Fig 4.1 Modified CMAC-PID controller

4.1.2 控制算法

改进型 CMAC-PID 控制器算法如下：

- ① 设置联想单元个数、泛化参数和量化等级。
- ② 初始化参数： $k=0$, CMAC 联想单元中的权值 $w(0)=0$ ， $u_p = u_n = u = 0, e(0) = 0$ 。

- ③ 设置学习速率 η ，PID 控制器的参数。

- ④ $k = k + 1$ ；

- 1) 根据公式 (4.1) 对输入矢量 $(Y_d(k), Y(k-1))$ 进行量化。

$$M(x) = \text{round}\left(\frac{x - x_{\min}}{x_{\max} - x_{\min}} \cdot M\right) \quad (4.1)$$

式中， round 为取整函数， x_{\max}, x_{\min} 分别是输入 x 的最大值和最小值， M 为 x_{\max} 对应的量化值。

- 2) 利用本文前面提出的 CMAC 概念映射算法，由公式 (3.21) 求出输入向量在联想空间单元中的映射地址，把映射地址中的内容求和即为 CMAC 的输出 $u_n(k)$ 。

- 3) PID 采用增量式学习算法，根据公式 (2.10) 计算出 PID 控制器的输出 $u_p(k)$ 。

- 4) 根据公式 (4.2) 计算出总的控制输入。

$$u(k) = u_p(k) + u_n(k) \quad (4.2)$$

式中， $u(k)$ 为控制器输入， $u_p(k)$ 为 PID 控制器输出， $u_n(k)$ 为 CMAC 的输出。

- 5) 根据公式 (4.3)，更新联想单元中的权值大小。

$$w(k) = w(k-1) + \eta(1 - |e(k)|_{mean}) \frac{e(k)}{c^2} \quad (4.3)$$

式中, η 为学习速率, $|e(k)|_{mean}$ 为绝对平均误差。

$$e(k) = Y_d(k) - Y(k) \quad (4.4)$$

⑤ 返回④执行。

4.1.3 仿真比较

① 给定为连续变化信号时两种控制器的比较

为了验证改进型 CMAC-PID 控制器的控制效果, 我们仍控制式 (3.23) 所示的非线性模型, 参考输入和控制参数也取为一样。当学习时间 $t = 40s$ 时, 在改进型 CMAC-PID 控制器控制下, 跟踪曲线和误差曲线和各控制器的输出分别如图 4.2、图 4.3 和图 4.4 所示。从图中可以看出, 一直到学习完为止, 系统都没有出现像原有 CMAC-PID 控制器控制时出现的崩溃现象。并且一开始加入 CMAC 后, 经很短时间, 输出就能很好的跟踪给定。从图 4.3 可以看出, 一开始 PID 控制器起主要作用, 误差较大, 经 CMAC 学习后误差迅速减小, 稳定到 0.02。这一点和传统的 CMAC-PID 控制器一样, 体现了 CMAC 学习速度快, 控制输出误差小的优点。

为进一步验证控制效果, 确认改进型 CMAC-PID 控制器不会随着长时间的学习而导致系统不稳定, 把学习时间在 $t = 40s$ 基础上再增加十倍令 $t = 400s$ 。跟踪曲线图和误差曲线图, 分别如图 4.5-图 4.7 所示。从三个图中可以看出跟踪效果很好, 没有不稳定现象出现, 并且跟踪误差一直保持 0.02 左右。另外我们把参数 (PID 参数, 学习速率 η , 泛化参数 C 和量化参数 q) 改变, 也没有出现不稳定现象。现在可以肯定地说, 改进型 CMAC-PID 控制器可以消除原有 CMAC-PID 控制器出现的不稳性现象, 提高了控制性能。




图 4.2 改进型 CMAC-PID 控制下的跟踪曲线 ($t = 40s$)

Fig 4.2 The tracing curve under modified CMAC-PID controller ($t = 40s$)




图 4.3 改进型 CMAC-PID 控制下的误差曲线 ($t = 40s$)

Fig 4.3 The error curve under modified CMAC-PID controller ($t = 40s$)




图 4.4 改进型CMAC-PID控制下的控制输出曲线 ($t = 40s$)

Fig 4.4 The output curve of controllers under modified CMAC-PID controller ($t = 40s$)






图 4.5 改进型CMAC-PID控制下的跟踪曲线 ($t = 400s$)

Fig 4.5 The tracing curve under modified CMAC-PID controller ($t = 400s$)

图 4.6 后5个周期的跟踪曲线 ($t = 400s$)Fig 4.6 the tracing curve of last five circle ($t = 400s$)图 4.7 改进型CMAC-PID控制下的误差曲线 ($t = 400s$)Fig 4.7 The error curve under modified CMAC-PID controller ($t = 400s$)

② 给定信号为恒定信号时三种控制器的比较

Miller提出的CMAC-PID控制器结构，是专门用于机器人轨迹跟踪问题的，这类问题的特点是理想轨迹含有丰富的状态，但对于方波或阶跃这种设定值较恒定的系统，效果不是很好，本文提出的改进型CMAC-PID控制由于引进了状态向量到CMAC的输入空间，成为反馈控制器的控制方案。对于跟踪设定值恒定的系统，也能取得令人满意的效果。下面用仿真进行说明：

控制对象为式 (3.23) 所示的非线性模型，参考信号为1Hz方波信号，各控制器的仿真参数如表4.1所示。其中PID控制器的三个参数，是在多次反复调整得到最优控制下的参数值。

表4.1 三种控制方案下的仿真参数设置

Table 4.1 The simulation parameter of three control scheme

PID控制器	传统CMAC-PID控制器	改进型CMAC-PID控制器
$k_p = 0.8$	$\eta = 0.05$	$\eta = 0.2$
$k_i = 0.1$	$q = 5/500$	$q = 5/500$
$k_d = 0.05$	$c = 50$	$c = 50$
	$k_p = 1.0$	$k_p = 0.5$

图4.8-图4.10分别为系统在PID控制、传统CMAC-PID控制和改进型CMAC-PID控制下的跟踪曲线。对比可以看出，PID控制和传统的CMAC-PID控制的超调比较大，而改进型CMAC-PID控制下，只有第一个周期，超调大，经过学习，能迅速的跟踪给定，大大减小了超调，加快了响应速度，体现了优良的控制效果，进一步验证，改进型CMAC-PID控制方案的有效性。




图4.8 PID控制下方波跟踪曲线




图 4.9 传统CMAC-PID控制下方波跟踪曲线

Fig 4.9 Square wave response under conventional CMAC-PID controller




图 4.10 改进型CMAC-PID控制下方波跟踪曲线

Fig 4.10 Quare wave response under modified CMAC-PID controller

4.1.4 小结

改进型 CMAC-PID 控制器中,通过系统误差调整联想存储空间中的权值,并采用变学习速率的结构,使得 CMAC 的学习为包含了 PID 控制器在内的整个系统的逆动态模型,有效克服原有控制结构,在跟踪连续变化信号时,由于 CMAC 和 PID 相互作用,产生过学习导致系统不稳定的现象。另外,把状态相量引入 CMAC 网络的输入空间,使 CMAC 成为反馈方案,充分利用了 CMAC 中已存储的信息,提高了抗干扰能力,在跟踪方波信号时,学习速度快,输出误差小,体现了良好的控制性能。

4.2 柴油发电机组

柴油发电机组是一种技术密集型的产品,涉及到内燃机、电机、自动控制等专业的技术。随着国民经济的发展,在柴油发电机组需求量逐年增长的同时,对柴油发电机组的功能、技术性能的要求也越来越高。

4.2.1 柴油发电机组的用途^[39]

柴油发电机组是一种用途非常广泛、地位十分重要的发电设备,它在国民经济各部门中得到了普遍应用。适用于市电不能到达的通信局站、矿区、林区、牧区和国防工程等场合。能作为独立电源,提供照明电和动力电。在有市电供电的单位或地区,当供电要求很高,不允许停电或需要尽快恢复供电的场合,如电厂、高层建筑、车站、医院、宾馆和银行等,柴油发电机组可以作为应急备用电源,一旦市电停电,能迅速提供稳定的交流电源。

在电厂中,柴油机发电机组的主要作用是当系统瓦解而造成厂用电终断时,

向汽轮机的盘车、顶轴油泵、交流润滑油泵、交流密封油泵等设备，提供事故电源，以保证机组安全停运。

4.2.2 柴油发电机组的组成及特点

柴油发电机组是内燃发电机组的一种，由柴油机、三相交流同步发电机、控制屏（包括自动检测、控制及保护装置）以及燃油箱、蓄电池等附件设备。

柴油发电机组的特点：

① 单机容量等级多

单机容量从几千瓦至几万千瓦，目前国产机组最大容量为几千千瓦，采用柴油发电机组作为应急和备用电源时，可采用一台或多台机组，装机容量可根据实际需要灵活配置。

② 热效率高、燃油消耗低

柴油机的有效热效率为 30%-46%，高压蒸汽轮机约 20%-40%，燃气轮机约 20%-30%，可以看出柴油机的有效热效率是比较高的，其燃油消耗较低。

③ 起动迅速，并能很快达到全功率

柴油机的起动迅速，在应急状态下 1 分钟内可以带到全负荷。它的停机过程也很短、可以频繁起停，适合作为应急发电机组或备用发电机组。

④ 维护操作简单，所需操作人员少，在备用期间保养容易。

4.2.3 机组的主要技术指标^[40]

① 电压整定范围

机组的空载电压整定范围为 95%—105%，保证机组在一定的负载下，输出电缆末端仍具有正常的工作电压。

② 稳态电压调整率

稳态电压调整率是指机组在负载变化后的稳定电压相对机组在空载时整定电压（额定电压）的偏差程度，用百分比表示。

稳态电压调率

$$\delta u = \frac{U_1 - U}{U} \times 100\% \quad (4.5)$$

式中：U——空载整定电压（额定电压），（伏）

U_1 ——负载渐变后的稳定电压的最大值（最小值），取三相线电压的平均值，（伏）

③ 机组的电压波形

机组要求发电机的理想波形是正弦波，但实际发电机的感应电势中含有三次及三次以上的高次谐波，因此发电机的电压波形会发生畸变，机组在空载额定电压时的线电压波形正弦性畸变率不大于 10%。

④ 电压和频率的瞬态调整率

当突加或突减负载时, 由于电枢反应等影响, 发电机端电压和频率会发生突然下降或升高的现象。

瞬态电压调整率是指机组负载突变时的瞬时变化电压与负载变化前后电压差值与额定电压的比值, 用百分比表示。

瞬态电压调整率:

$$\delta U_s = \frac{U_s - U}{U} \times 100\% \quad (4.6)$$

式中: U ——额定电压

U_s ——负载突变时的瞬时电压最大值和最小值

瞬态频率调整率是指机组在突加或突减负载时, 机组的瞬时变化频率与负载变化前的频率的差值和额定频率的比值, 用百分比表示。

瞬态频率调整率:

$$\delta f_s = \frac{f_h - f_s}{f} \times 100\% \quad (4.7)$$

式中: f ——额定频率

f_h ——负载变化前的稳定频率

f_s ——负载变化时的频率最大值和最小值

⑤ 电压和频率稳定时间

机组的负载突变时, 其电压和频率会产生突然下降或升高现象, 从负载突变时起至电压或频率从开始稳定所需要的时间为电压或频率稳定时间。

电压稳定时间指从电压突变起至电压开始稳定与稳定电压相差 $\pm \delta u$ 范围内所需的时间。

频率稳定时间指从频率突变起至频率开始稳定至频率波动范围内所需要的时间。

4.2.4 柴油发电机组调速系统

对于柴油发电机组而言, 发动机调速系统性能的好坏是决定整个发电机组电气性能(如: 频率特性、电压特性及带载能力等) 的关键。

动力机械上最早出现的转速自动调节装置, 即调速器是1784年J.瓦特 (James Watt) 发明的用于蒸汽机上的离心式机械调速器, 它揭开了调速器历史的第一页。离心式机械调速器作为第一代调速器, 调速精度较差, 主要用于小型发动机调速。四十年代末五十年代初, 出现了间接作用的机械液压式调速器, 这是调速器发展的第二代。上述两代调速器中, 由于敏速装置和控制装置都是机械元件来实现。因而, 不可避免地存在惯性滞后及摩擦阻力大等固有缺陷。这就决定了它难以实现

较为复杂的调节精度和自动化程度的要求。

六十年代,美国WOODWARD公司将新兴的电子技术成功地应用于柴油机调速系统,推出了一种全新的调速器,即2301/EG3P型电液调速器。它由转速传感器、电子控制器和电液执行器三个基本部分组成。该调速器的转速反馈环节采用了非接触式磁电传感器,通过频率电压转换器得到转速值。控制部分采用模拟电子线路组成的PID调节器,其输出电信号驱动电液执行器,以输出机械角位移,进而驱动喷油泵齿条运动,使发动机供油量与外界负载变化相适应,达到转速调节目的。该电液调速器奠定了模拟电子调速器—第三代调速器的基本结构模式。六十年代至八十年代初,是模拟式电子调速技术迅速发展的鼎盛时期,并在越来越多的场合取代了传统的机械-液压调速器。模拟式电力调速器虽然可以大大提高柴油机调速精度和扩展系统控制功能,但是由于其各项功能全部依靠硬件电路加以实现,因而通用性较差,而且扩展功能与系统复杂程度、成本及可靠性之间的矛盾也难以很好解决。

随着数字集成电路以及计算机控制技术的发展。自八十年代以来,又出现了以微处理器为控制器核心的第四代调速器—数字式电子调速器,在数字式电子调速器中,控制器由专门的控制用微处理器和一系列输入、输出接口电路所构成。除了各输入、输出信号的转换外,系统地各项控制与调节功能主要靠软件编程加以实现。因而对硬件的依赖程度大大降低,只需改变控制软件和配置必要的接口,就可以用于各种系统完成不同的控制功能。这一特点决定了它具有极强的适应性和几乎无限的功能扩展能力。

4.2.5 柴油机电子调速的基本原理^[41]

柴油发动机调速系统是通过安装在飞轮壳上的转速电磁传感器检测出转速的变化,通过电子调速器的控制,由执行器带动油门拉杆,调节供油量大小,从而实现转速自动调节的目的。调速系统主要由转速检测单元、电子调速器单元及执行机构等部分组成。柴油机调速系统结构方框图见图4.11。




图 4.11 柴油机调速系统方框结构图

Fig 4.11 The structure diagram of speed governing system of diesel

柴油机调速系统实质上是属于速度控制系统,即速度闭环控制。柴油机调速系

统因其具有非线性、时变不确定性等特性,难以对其建立精确的数学模型。PID 控制作为一种实际生产过程普遍采用的工程控制方法,具有计算量小、实时性强、易于实现等特点,因此,在调速领域被广泛采用。

4.2.6 柴油机数字电子调速器的控制策略

① PID (比例、积分、微分) 控制算法在数字式调速器中的应用

柴油机转速控制实质上,是调速器根据柴油机的运行状况和外界负载变化,通过调整燃油泵的齿条位置以及改变供油量,从而使柴油机的转速保持在给定的范围内。因此,调速器对柴油机的转速控制属于闭环控制。从闭环控制理论上,合理地建立系统的数学模型,是进行分析研究和设计的基础及关键。但是,由于柴油机结构复杂、影响因素众多,其工作过程的非线性、时变性和不确定性,使得用数学方法对其特性加以准确描述具有很大困难,甚至是不可能的。

因此,这就限制了过于依赖精确数学模型的控制方法在柴油机调速系统中的应用。另外,由于成本等因素,控制器普遍采用单片机系统,像其它行业的自动控制装置一样,目前实际应用中的电子调速器,无论是模拟的还是数字的,控制方案大多还采用PID控制方式。但是,由于PID控制器本身稳定性和快速型之间的矛盾,以及柴油机在不同工况下其系统参数存在着较大的非线性。因此,实际应用的柴油机调速系统都必须针对PID控制器的不足和柴油机的特点,对PID控制算法进行改进,使之具有非线性的特点。

② 自适应控制

1991年,加拿大Calgary大学的S.Roy等人将自适应控制算法应用于柴油机转速控制中,先后进行了算法设计、仿真分析,并在WOODWAED公司的发动机模拟器上进行了模拟实验研究,仿真分析和实验结果显示,该算法的控制效果要好于PID控制方式。但是由于这种算法需要实时的进行参数辨识,计算量大,对硬件要求高。

③ 模糊控制

模糊控制是建立在扎德教授创立的模糊集合理论基础上的异类智能控制,其核心就是模糊推理。它不依赖于控制对象的数学模型,而是根据人的控制经验。通过模仿人来进行控制决策。因此,模糊控制器可以实现人的某些智能。自1974年首次成功应用于锅炉和蒸汽机控制以来,应用越来越广泛,表现出强大生命力,1993年Martinez和Jamshidi将模糊模糊控制应用于发动机的怠速控制中,通过仿真实验与PID控制相比较,无论是超调量(6.0%比12%),还是调整时间(1.7s比1.75s)都优于PID控制。

另外, H_{∞} 控制、神经网络控制等新兴控制方法在转速控制中也有所研究。总之柴油机数字式调速系统中,控制策略的研究既与控制理论的发展密切相关,也

与计算机技术的发展密切相连。虽然其它控制算法也逐渐有所应用，但目前经典的PID控制在柴油机转速控制中仍占据主导地位。

4.3 柴油发电机组建模

在 SIMULINK 环境下建立的柴油发电机组系统模型如图 4.12 所示。包括柴油机模型、同步发电机模型、励磁系统及其负载模型，下面分别论述。

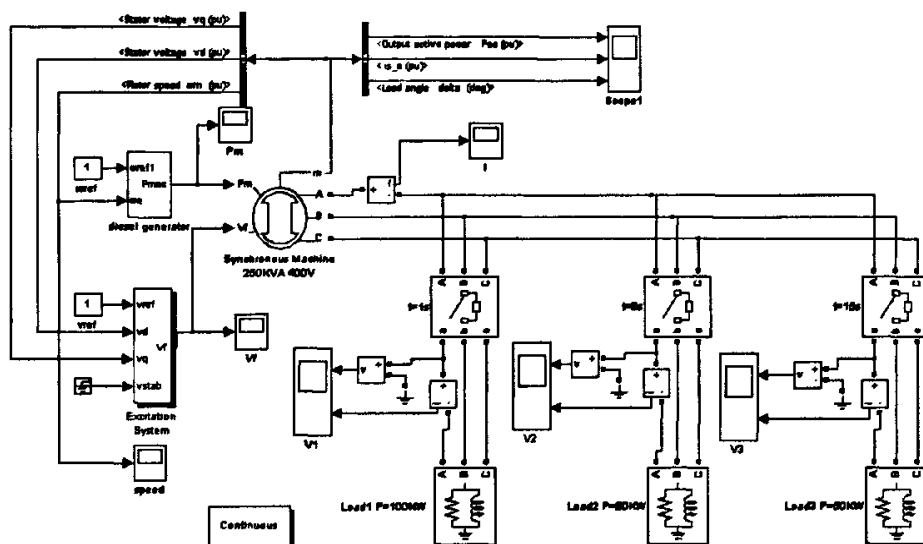


图 4.12 柴油发电机组及其负载模型

Fig 4.12 The model of diesel generator set and its loads

4.3.1 柴油机及其调速系统

柴油机及其调速系统方框图如图 4.13 所示。图中 $\Delta\omega$ 为转速偏差， P_{mec} 为输出机械功率。




图 4.13 柴油机调速系统框图

Fig 4.13 The diagram of speed governing system of diesel

柴油机内的状态变量不止一个，但在实际设计中采用高阶模型则较困难。实践表明采用一阶近似模型，不仅简化了设计工作，并且能达到满意的效果^[3]。柴油机的运动方程：

$$T_a y'(t) + y(t) = \eta(t - \tau) - \lambda(t) \quad (4.8)$$

式中, $y(t)$ ——柴油机转速, 是时间 t 的函数;

$\eta(t)$ ——控制燃油量的齿条位移, 时间 t 的函数;

τ ——纯滞后时间, s;

$\lambda(t)$ ——扰动, 是时间 t 的函数;

T_a ——柴油机时间常数, s;

将柴油机模型近似于一阶惯性纯滞后环节:

$$G_1(s) = e^{-\tau s} / T_a s + 1 \quad (4.9)$$

柴油机油门执行机构为可逆直流伺服电机, 方框图如图 4.14 所示。




图 4.14 执行机构方框图

Fig 4.14 The diagram of actuator

4.3.2 同步发电机

同步发电机模型用 MATLAB 软件中的 SimPowerSystems 仿真模块进行建模。机械部分数学表达式:

$$\begin{cases} \Delta\omega(t) = \frac{1}{2H} \int_0^t (T_m - T_e) dt - K_d \Delta\omega(t) \\ \omega(t) = \Delta\omega(t) + \omega_0 \end{cases} \quad (4.10)$$

式中, $\Delta\omega(t)$ ——转速偏差;

H ——惯性常数;

T_m ——机械转矩;

T_e ——电磁转矩;

K_d ——阻尼系数;

$\omega(t)$ ——转子速度;

ω_0 ——额定转速 (标么值为 1);

MATLAB 中, 建立的同步发电机机械部分模型如图 4.15 所示:




图 4.15 同步发电机机械部分模型

Fig 4.15 The mechanical model of synchro generator

同步发电机的电气部分用六阶状态方程表示，考虑了定子、励磁和阻尼绕组的动态特性。模型的等效电路可以用 d 、 q 轴参考模型电路描述，如图 4.16 所示。



 图 4.16 同步发电机 d - q 轴电路模型

 Fig 4.16 The d - q circuit model of synchro generator

模型数学方程式如下：

$$\begin{cases} V_d = R_s i_d + \frac{d}{dt} \varphi_d - \omega_R \varphi_q \\ V_q = R_s i_q + \frac{d}{dt} \varphi_q + \omega_R \varphi_d \\ V'_{fd} = R'_{fd} i'_{fd} + \frac{d}{dt} \varphi'_{fd} \\ V'_{kd} = R'_{kd} i'_{kd} + \frac{d}{dt} \varphi'_{kd} \\ V'_{kq1} = R'_{kq1} i'_{kq1} + \frac{d}{dt} \varphi'_{kq1} \\ V'_{kq2} = R'_{kq2} i'_{kq2} + \frac{d}{dt} \varphi'_{kq2} \end{cases} \quad (4.11)$$

式中：

$$\begin{aligned}\varphi_d &= L_d i_d + L_{md}(i'_{fd} + i'_{kd}) \\ \varphi_q &= L_q i_q + L_{mq} i'_{kq} \\ \varphi'_{fd} &= L'_{fd} i'_{fd} + L_{md}(i_d + i'_{kd}) \\ \varphi'_{kd} &= L'_{kd} i'_{kd} + L_{md}(i_d + i'_{fd}) \\ \varphi'_{kq1} &= L'_{kq1} i'_{kq1} + L_{mq} i_q \\ \varphi'_{kq2} &= L'_{kq2} i'_{kq2} + L_{mq} i_q\end{aligned}$$

下标 d 、 q 分别代表 d 轴和 q 轴； R 、 s 代表转子和定子； l 、 m 代表漏电感和磁化电感； f 、 d 代表励磁和阻尼绕组。

可以设置以下参数，对同步发电机进行建模：转子类型，视在功率、线电压和频率，定子、励磁、阻尼和机械参数。

4.3.3 励磁系统

同步发电机的励磁系统模型，采用 SimPowerSystem 模块建模。模型如图 4.17 所示。其中：

- v_{ref} —— 发电机定子终端电压；
- v_d —— 发电机 d 轴电压；
- v_q —— 发电机 q 轴电压；
- v_{stab} —— 连接系统稳定器的接口；
- v_f —— 向同步发电机提供的励磁电压；

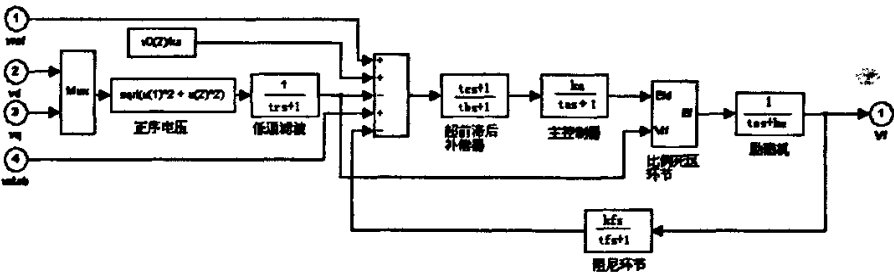


图 4.17 同步发电机励磁系统模型

Fig 4.17 The excitation model of synchro generator

4.4 改进型 CMAC-PID 控制器用于柴油发电机组调速系统

在火电厂中，应急柴油机发电机组的主要作用是当系统瓦解，造成厂用电终端断时，向汽轮机的盘车、顶轴油泵、交流润滑油泵、交流密封油泵等设备，提供事故电源，以保证机组安全停运。作为备用电源，应急柴油发电机组应具备在一定的时间内，起动、升速并带动负载的能力。同时还要保持发电机终端电压和频率的稳定，不因为系统加载或去除负载时，产生大的波动，保证供电质量。

应急柴油发电机组在保安段失电时，自动起动、升速并建压，如果这时同时投

入所有的负载，电压和频率波动较大，所需的柴油发电机组功率也比较大，因此一般采用自起动负载程序，将所有的负载分成若干步投入，即能保证柴油发电机组不被拖垮，又能使负载最快最有效地投入。如图 4.12 所示的应急柴油发电机组仿真模型中，包括柴油机及其调速系统（diesel）、励磁系统（Excitation System）、同步发电机（Synchronous Machine）及其负载（Load1-Load3）。

励磁系统仿真参数： $tr = 0.001$ ， $ka = 1000$ ， $ta = 0.001$ ， $ke = 1$ ， $te = 0$ ， $kf = 0.005$ ， $tf = 0.86$ ；

同步发电机主要参数：视在功率(P_n)=250kVA，额定线电压(V_n)=400V，频率(f_n)=50Hz；

柴油机调速系统采用常规数字 PID 控制器时，仿真参数：采样时间 $ts = 0.01s$ ， $k_p = 12$ ， $k_i = 18$ ， $k_d = 7$ 。分别在第 1s、8s 和 15s 时投入负载 1（100kw，40%）、负载 2（80kw，32%）和负载 3（50kw，20%），发电机转速曲线（标么值）如图 4.18 所示。

采用改进型 CMAC-PID 控制时，仿真参数： $M = 300$ ， $C = 50$ ， $q = 5/500$ ， $\eta = 0.1$ ， $\alpha = 0.003$ ， $ts = 0.01s$ ， $k_p = 30$ ， $k_i = 0$ ， $k_d = 9.5$ 。顺序投入负载时，发电机转速曲线、励磁电压曲线、柴油机输出机械功率、机组输出有功功率、机组输出相电流（a 相）及各个负载上面的相电压、电流分别如图 4.19-图 4.26 所示。




图 4.18 常规 PID 控制的转速曲线

Fig 4.18 The speed curve under the control of general PID controller




图 4.19 改进型 CMAC-PID 控制的转速曲线

Fig 4.19 The speed curve under the control of modified CMAC-PID controller

转速（频率）瞬态调整率和稳定时间，是应急柴油发电机组重要的电气性能指标，国家标准《工频柴油发电机组通用技术条件》及《自动化柴油发电机组通用技术条件》都对其有严格的规定^[42]。

比较图 4.18 和图 4.19 两种控制方式下的发电机转速曲线，负载顺序投入时的转速（频率）瞬态调整率和调整时间如表 4.2 所示。常规 PID 控制在第 1s 突加负载 1，转速（频率）瞬态调整率为 12%，第 6s 时恢复稳定；而 CMAC-PID 控制时，转速（频率）瞬态调整率为 9.3%，第 4s 恢复稳定。同样第 8s 突加负载 2，常规 PID 控制时转速（频率）瞬态调整率为 9%，13s 恢复稳定；改进型 CMAC-PID 控制时转速（频率）瞬态调整率为 8%，11s 时恢复稳定。第 15s 突加负载 3，常规 PID 控制时，转速（频率）瞬态调整率为 5%，20s 时恢复稳定；采用改进型 CMAC-PID 控制时转速（频率）瞬态调整率为 4.4%，17.5s 时恢复稳定。综上可以看出改进型 CMAC-PID 控制时，柴油发电机组调速系统有更好的动态特性，突加负载时，转速（频率）瞬态调整率小，稳定时间短，使机组输出电的频率特性好，保证供电质量。体现了改进型 CMAC-PID 控制的优势。

表 4.2 两种方式控制下顺序投入负载时的转速瞬态调整率和稳定时间

Table 4.2 The transient adjustment rate and stabilization time when the loads are input controlled by two control scheme

	常规 PID 控制时		改进型 CMAC-PID 控制时	
	转速（频率）瞬 态调整率（%）	转速（频率） 稳定时间（s）	转速（频率）瞬 态调整率（%）	转速（频率） 稳定时间（s）
投入负 载 1 时	12	5	9.3	3
投入负 载 2 时	9	7	8	4.5
投入负 载 3 时	5	5	4.4	2.5




图 4.20 励磁电压曲线

Fig 4.20 The curve of exciting voltage




图 4.21 柴油机输出机械功率

Fig 4.21 The mechanical power of diesel




图 4.22 发电机组输出有功功率

Fig 4.22 The output active power of generator set




图 4.23 机组输出相电流

Fig 4.23 The output phase current of generator set




图 4.24 负载 1 的相电压和相电流

Fig 4.24 The phase voltage and current of load 1




图 4.25 负载 2 的相电压和相电流

Fig 4.25 The phase voltage and current of load 2




图 4.26 负载 3 的相电压和相电流

Fig 4.26 The phase voltage and current of load 3

从图 4.20 所示励磁电压曲线图可以看出，在突加负载时，励磁电压有波动，1-2s 内在新位置恢复稳定，保证机组输出电的电压稳定。从图 4.21 和图 4.22 可以看出顺序增加负载时，柴油机输出的机械功率和发电机输出的有功功率都相应增加，对比两图柴油机输出的机械功率要高于发电机的有功功率。图 4.23 所示的机组输出电流曲线，电流在突加负载时波动，在励磁调压装置及调速系统的调节下，逐渐恢复稳定；还可以看出，输出电流随着负载的增加逐渐变大。图 4.24-图 4.26 分别为负载 1-3 上的电压、电流波形图，在负载没有投入时，电压、电流为 0，负载投入后，电压、电流都出现波动并很快稳定，符合实际状况。

4.5 本章小结

本章针对传统的 CMAC-PID 控制结构由于 CMAC 和 PID 相互作用，产生过学习，导致系统不稳定的现象，在原有控制结构基础上提出了一种改进方案。改进后的 CMAC-PID 控制器通过系统误差调整联想存储空间中权值的大小，同时采用变学习速率的结构，使得 CMAC 的学习为包含了 PID 控制器在内的整个系统的逆动态模型，有效克服了原有控制方案，在跟踪连续变化时，产生过学习最终导致系统不稳定的现象。另外，把状态相量引入 CMAC 网络的输入空间，充分利用了 CMAC 中已存储的信息，提高了抗干扰能力。文中给出了改进型 CMAC-PID 控制器的详细控制算法。分别就输入信号为连续变化的正弦信号和较为恒定的方波信号两种情况，通过仿真，改进型 CMAC-PID 克服了不稳定现象，在跟踪方波




图 4.26 负载 3 的相电压和相电流

Fig 4.26 The phase voltage and current of load 3

从图 4.20 所示励磁电压曲线图可以看出，在突加负载时，励磁电压有波动，1-2s 内在新位置恢复稳定，保证机组输出电的电压稳定。从图 4.21 和图 4.22 可以看出顺序增加负载时，柴油机输出的机械功率和发电机输出的有功功率都相应增加，对比两图柴油机输出的机械功率要高于发电机的有功功率。图 4.23 所示的机组输出电流曲线，电流在突加负载时波动，在励磁调压装置及调速系统的调节下，逐渐恢复稳定；还可以看出，输出电流随着负载的增加逐渐变大。图 4.24-图 4.26 分别为负载 1-3 上的电压、电流波形图，在负载没有投入时，电压、电流为 0，负载投入后，电压、电流都出现波动并很快稳定，符合实际状况。

4.5 本章小结

本章针对传统的 CMAC-PID 控制结构由于 CMAC 和 PID 相互作用，产生过学习，导致系统不稳定的现象，在原有控制结构基础上提出了一种改进方案。改进后的 CMAC-PID 控制器通过系统误差调整联想存储空间中权值的大小，同时采用变学习速率的结构，使得 CMAC 的学习为包含了 PID 控制器在内的整个系统的逆动态模型，有效克服了原有控制方案，在跟踪连续变化时，产生过学习最终导致系统不稳定的现象。另外，把状态相量引入 CMAC 网络的输入空间，充分利用了 CMAC 中已存储的信息，提高了抗干扰能力。文中给出了改进型 CMAC-PID 控制器的详细控制算法。分别就输入信号为连续变化的正弦信号和较为恒定的方波信号两种情况，通过仿真，改进型 CMAC-PID 克服了不稳定现象，在跟踪方波

信号时,也具有学习速度快,输出误差小的优点,适合于非线性实时控制,验证了改进方案的有效性。

对于柴油发电机组而言,发动机调速系统性能的好坏是决定整个发电机组电气性能的关键。而柴油发电机组的实时性和非线性非常突出,随转速、负荷及其它运动条件的变化,模型参数将发生很大的变化,采用常规 PID 控制器不足以补偿参数变化给系统带来的影响。首先建立了火电厂应急柴油发电机组在 MATLAB SIMULINK 环境下的仿真模型,提出的改进型 CMAC-PID 控制器用于柴油发电机组调速系统中,通过仿真分析,验证了所建模型的正确性和应急柴油发电机组在改进型 CMAC-PID 控制下比常规 PID 控制下有更好的动态性能,转速(频率)瞬态调整率小,稳定时间短,克服了常规控制器所不能避免的一些弊端,提高了控制效果。

5 结论与展望

5.1 结论

本论文研究神经网络与 PID 复合控制方案,以解决常规 PID 控制器在控制非线性、时变性突出的系统时,参数整定难、不能实时调参数和鲁棒性不强的问题。现有神经网络与 PID 的复合控制方案中,基于单神经元的 PID 控制,虽然也具有神经网络的一些优点,但由于受到单层网络的局限性,这种结构只具备单层线性分类能力,而不具备逼近非线性函数的能力,在控制复杂系统时效果不好。基于神经网络在线调整 PID 参数的控制结构,神经网络所具有的任意非线性表达能力,可以通过对系统性能的学习实现具有最佳组合的 PID 控制,但是这种控制结构一般采用全局学习神经网络(如 BP 网络),全局学习神经网络的缺点,也决定了这种神经网络 PID 控制器的缺点,学习速度慢,并且容易陷入局部极小。针对一个具体的实例,通过仿真,揭示了这种控制结构在跟踪方波信号时,反应比较“迟钝”,跟踪误差大,不能达到实时控制的要求。

第三种神经网络 PID 复合控制方案—小脑模型神经网络(CMAC)与 PID 的复合控制,小脑模型是一种局部学习神经网络,学习速度快(比一般神经网络快一个数量级),并且易于软、硬件实现,适合于非线性实时控制。针对传统的 CMAC-PID 控制方案,存在 CMAC 与 PID 在控制过程中相互冲突,导致系统不稳定的现象,文中提出了改进方案,并给出了详细的控制算法。通过仿真研究,改进型 CMAC-PID 控制器消除了不稳定现象,并且在跟踪方波信号时的误差也小于传统 CMAC-PID 控制器和常规 PID 控制器,验证了改进方案的有效性。论文将改进型的 CMAC-PID 控制器用于自动化柴油发电机组调速系统中,对柴油发电机组而言,发动机调速系统性能的好坏是决定整个发电机组电气性能的关键。而柴油发电机组的实时性和非线性非常突出,随转速、负荷及其它运动条件的变化,模型参数将发生很大的变化,采用常规 PID 控制器不足以补偿参数变化给系统带来的影响。论文建立了火电厂应急柴油发电机组在 MATLAB SIMULINK 环境下的仿真模型,通过仿真分析,验证了所建模型的正确性和应急柴油发电机组在改进型 CMAC-PID 控制下比常规 PID 控制下有更好的动态性能,两个重要的性能指标,转速(频率)瞬态调整率小和稳定时间短,克服了常规控制器所不能避免的一些弊端,提高了控制效果。

5.2 展望

本文提出了改进型 CMAC-PID 控制方案,消除了原控制方案的不稳定现象,

将改进型 CMAC-PID 用于应急柴油发电机组调速系统中，也取得了良好的控制效果。但对于神经网络以及神经网络控制器还有很大的改善空间。对于后续的研究工作，应把研究重点放于：

- ① 控制实际对象，验证仿真和实验的差距；
- ② 神经网络的稳定性和收敛性问题，对于 CMAC，它的量化、概念映射、实际映射、学习算法还需进一步研究；
- ③ 对于神经网络控制（包括神经网络 PID 复合控制）系统的稳定性和收敛性问题；
- ④ 学习算法的实时性；
- ⑤ 神经网络控制器和辨识器的模型和结构；

致 谢

本文的研究工作是在我的导师侯世英副教授的精心指导和悉心关怀下完成的，在我的学业和论文的研究工作中无不倾注着侯老师辛勤的汗水和心血。导师的严谨治学态度、渊博的知识、无私的奉献精神使我深受的启迪。从尊敬的侯老师身上，我不仅学到了扎实、宽广的专业知识，也学到了做人的道理。在此我要向侯老师致以最衷心的感谢和深深的敬意。

在多年的学习生活中，还得到了吕厚余教授的悉心指导和热心帮助，在此向吕老师表示衷心的感谢！

在研究生学习和课题研究过程中，我的师兄弟万江、刘庚、王凌谊对我帮助很大。也得到了王得朝、祝石厚、郑涵博、索丽娟、汪瑶等师弟师妹的支持和鼓励。在此向所有关心帮助过我的老师、同学们表示深深的感谢！

另外要特别感谢我父母，没有他们多年来的关心和支持，我的学业同样无法顺利完成！

最后，衷心地感谢在百忙之中评阅论文和参加答辩的各位专家、教授！

时文飞

2007年4月 于重庆

参考文献

- [1] 沈永福, 吴少军, 智能 PID 控制综述, 工业仪表与自动化装置, 2002, No.6: 11-13.
- [2] 胡俊达, 胡慧, 黄望军, 自适应 PID 控制技术综述, 中华纸业, 2005, Vol.26, No.2: 48-51.
- [3] 廖常初, S7-300/400 PLC 应用技术, 北京, 机械工业出版社, 2002.89-93.
- [4] 孙增圻, 张再兴, 智能控制的理论与技术, 控制与决策, 1996, Vol.11, No.1: 1-4.
- [5] 李少远, 席裕庚, 智能控制的新进展(II), 控制与决策, 2000, Vol.2, No.3: 137-139.
- [6] 李浚泉, 智能控制发展过程综述, 工业控制计算, 1999, No.3: 30-34.
- [7] 蔡自兴, 人工智能控制, 北京, 化学工业出版社, 第一版, 2005.7-12.
- [8] 刘金琨, 智能控制, 北京, 电子工业出版社, 第一版, 2005.1-4.
- [9] 罗均, 谢少荣等, 智能控制工程及其应用实例, 北京, 化学工业出版社, 2005.1-9.
- [10] 陆祥光, 裴旭东, 人工神经网络技术及应用, 中国电力出版社, 第一版, 2003.1-6.
- [11] 李少远, 王景成, 智能控制, 北京, 机械工业出版社, 2005.95-105.
- [12] 孙增圻, 智能控制理论与技术, 北京, 清华大学出版社, 1997.194-201.
- [13] 曹承志, 王楠, 智能技术, 北京, 清华大学出版社, 第一版, 2004.17-153.
- [14] 焦李成, 神经网络的应用与实现, 西安电子科技大学出版社, 1996.256-360.
- [15] 陶永华, 新型 PID 控制及其应用, 机械工业出版社, 2002.149-158.
- [16] 夏定纯, 徐涛, 人工智能技术与方法, 华中科技大学出版社, 2004.201-210.
- [17] 何继爱, 达正花, BP 神经网络 PID 控制器仿真实现, 甘肃联合大学学报(自然科学版), 2005, Vol.19, No.2: 31-34.
- [18] 朱海峰, 李伟, 张林, 基于 BP 神经网络整定的 PID 控制, 动力学与控制学报, 2005, Vol.3, No.4: 93-96.
- [19] 阎树田, 姜志科, 牛万才, 骆敬辉, 基于 BP 神经网络的模型参考自适应 PID 控制器的研究, 现代制造工程, 2006, No.9: 112-114.
- [20] J.S.ALBUS, A New Approach to Manipulator: The Cerebellar Model Articulation Controller(CMAC), Journal of Dynamic Systems, Measurement and Control 1975, pp220-227.
- [21] 王国栋, 刘相华, 金属轧制过程人工智能优化, 北京, 冶金工业出版社, 第一版, 2000.60-61.
- [22] 苏刚, 陈增强, 袁著祉, 小脑模型关节控制器(CMAC)理论及应用, 仪器仪表学报, 2003, Vol.24, No.4: 269-273.
- [23] 阮晓钢, 神经计算科学, 北京, 国防工业出版社, 第一版, 2006.425-433.
- [24] 周旭东, 王国栋, CMAC 神经网络的概念映射算法, 东北大学学报, 1996, Vol.17, No.6: 619-623.

- [25] 刘金琨, 先进PID控制及MATLAB仿真, 北京, 电子工业出版社, 第2版, 2004.183-185.
- [26] W.Thomas Miller, Real-Time Dynamic Control of an Industrial Manipulator Using a Neural-Network-Based Learning Controller, IEEE TRANSACTIONS ON ROBOTICS AND AUTOMATION, 1990, Vol.6, No.1:1-9.
- [27] Ke Zhang, A Study on Intelligent Control for Hybrid Actuator, ISSN2006, LNCS 3972, 2006, pp1116-1123.
- [28] Jian-qiang Li, Ji-zhen and Yu-guang Niu, Application of Cerebellar Model Articulation Control in Reheated-steam System, 2004 IEEE Region 10 Conference, 2004, pp578-580.
- [29] Chan-Mo Kim, Kwang-Ho and Chao, YB, Hardware design of CMAC neural network for control applications, 2003 Proceedings of the International Joint Conference on Neural Networks, 2003, Vol.2, No2:953-958.
- [30] Wang Huanmin, Xi Wenming, Zhu jianying, Control Schemes for CMAC Neural Network-Based Visual Servoing, Chinese Journal of Mechanical Engineering, 2003, Vol.16, No.3:25-259.
- [31] 蒋志明, 林廷圻, 黄先祥, 基于CMAC的带有未知负载干扰电液位置伺服系统的自学习控制, 控制与决策, 2000, Vol.15, No.3: 368-374.
- [32] Kai Keng Ang and Chai Qwek, Improved Momentum, Neighborhood, and Averaged Trapezoidal Output, IEEE TRANSACTIONS ON SYSTEMS MAN AND CYBERNETICS, 2000, Vol.30, No.3:491-500.
- [33] C.C.Lin and F.C.Chen, On a New CMAC Control Scheme, and Its Comparisons With the PID Controllers, Proceedings of American Control Conference, 2001, pp769-774.
- [34] Zhiming Jiang and Shengwei Wang, A General Learning Scheme for CMAC-based Controller, Neural Processing Letters, 2003, Vol.18, pp125-138.
- [35] Fu-Chuang Chen and Chih-horng Chang, Practical Stability Issues in CMAC Neural Network Control Systems, IEEE TRANSACTIONS ON CONTROL SYSTEMS TECHNOLOGY, Vol.4, No.1:86-91.
- [36] K.E.Yeager, Modeling of Emergency Diesel Generators in an 800 Megawatt Nuclear Power Plant, IEEE Transactions on Energy Conversion, 1993, Vol.8, No3 :433-441.
- [37] I.D.Hassan., Evaluating the Transient Performance of Standby Diesel-Generator Units by Simulation, IEEE Transactions on Energy Conversion, 1992, Vol.7, No3: 470-475.
- [38] 赵光宙, 高军, 杨志家, 柴油机模型参考自适应调速系统的研究, 内燃机工程, 1995, Vol16, No.4: 26-33.
- [39] 陈东栋, 从电力发展看柴油发电机组的前景[J], 移动电源与车辆, 1998, No.1:3-9.
- [40] 刘杰, 安国建, 现代柴油机使用和检测, 人民交通出版社, 2000.

- [41] 曹世宏, 程志军, 张福才, 刘剑飞, 柴油发电机组电子调速技术综述, 2004, No.4:18-21.
- [42] 袁春, 张寿珍, 柴油发电机组, 北京, 人民邮电出版社, 第一版, 2003.2-10.
- [43] S.COMMURI, F.L.LEWIS, CMAC Nerual Networks for Control of Nolinear Dnamicl Systems: Structure, stability and Passivity, Automatica, 1997, Vol.31,No.4:635-641.
- [44] Chun-Shin Lin and Hyongsuk Kim, CMAC-Based Adaptive Critic Self-Learning Control,IEEE TRANSACTIONS ON NERUAL NETWORK,1991,Vol.2,No.5:30-533.
- [45] Changjiang Shang, Donald Reay and Barry Willianms,Adapting CMAC Neural Networks with Constrained LMS Algorithm for Efficient Torque Ripple Reduction in Swithed Reluctance Motors,IEEE TRANSACTIONS ON CONTROL SYSTEMS TECHNOLOGY,V

附 录

作者在攻读硕士学位期间发表的论文目录

- [1] 时文飞, 侯世英, 李学远, 万江, 基于 CMAC 与 PID 复合控制的柴油机调速系统, 自动化技术与应用, 2006, Vo25, No.4: 11-13.
- [2] 侯世英, 时文飞, 万江, 基于 CMAC-PID 控制的柴油发电机组的建模与仿真, 系统仿真学报, 已录用, 将于 2007 年第 13 期发表
- [3] 时文飞, 侯世英, 张柯, 徐志向, PLC 与计算机的串行通信程序设计, 机床电器, 2005, No.4:31-33.
- [4] 万江, 侯世英, 时文飞, 基于 MATLAB 的高压变频器的建模与仿真, 佳木斯大学学报, 已录用
- [5] 侯世英, 万江, 时文飞, 以单相五电平逆变器为例的多载波 PWM 方法的分析比较, 电子技术应用, 已录用